

Modélisation des Dépendances entre Branches d'Assurance par la Théorie des Copules

Hind Ourassane Ihssan Malki Saida Sessid

Application à la Détermination du Besoin
en Fonds Propres d'un Assureur Non-Vie

Données CASdatasets (freclaimset3multi9207,
 freclaimset3fire9207, freclaimset3dam9207)
Outils Python : numpy, scipy, pyvinecopulib
 R : CASdatasets, copula

24 mai 2026

Résumé

Ce rapport étudie la modélisation des dépendances entre branches d'assurance non-vie à l'aide de la théorie des copules, dans l'objectif d'évaluer plus rigoureusement le besoin en fonds propres d'un assureur. Les approches classiques fondées uniquement sur la corrélation linéaire de Pearson présentent en effet plusieurs limites majeures : absence d'invariance par transformation monotone, incapacité à représenter les dépendances non linéaires et impossibilité de caractériser entièrement une distribution jointe.

Après avoir exposé ces limites, le rapport développe les fondements théoriques des copules à travers le théorème de Sklar, la séparation entre distributions marginales et structure de dépendance, les mesures de concordance de Kendall et Spearman ainsi que les bornes de Fréchet-Hoeffding. Les principales familles de copules sont ensuite étudiées — gaussienne, Student- t , Clayton, Gumbel et Frank — avec une attention particulière portée aux phénomènes de dépendance de queue, essentiels en gestion des risques extrêmes.

Une application actuarielle complète est réalisée sur un portefeuille réel d'un assureur français non-vie issu des bases `CASdatasets` (`freclaimset3multi9207`, `freclaimset3fire9207`, `freclaimset3dam9207`) couvrant la période 1992–2006 et composé de huit garanties. Après ajustement des lois marginales, les dépendances sont analysées à l'aide des coefficients de Kendall et de Spearman. Les copules bivariées sont sélectionnées par la méthode IFM et les critères AIC/BIC avant d'être intégrées dans une Vine Copule multidimensionnelle.

Une simulation Monte Carlo de 100 000 scénarios est ensuite effectuée afin d'estimer la distribution agrégée des pertes et les besoins en capital via la VaR et la TVaR. Les résultats mettent en évidence 14 dépendances positives significatives sur 28 paires étudiées, ainsi qu'une dépendance de queue supérieure pour les branches liées aux risques climatiques, modélisée principalement par la copule de Gumbel. L'étude montre finalement que l'hypothèse d'indépendance entre branches conduit à une surestimation du capital requis de 12% à 32% selon le niveau de confiance considéré, soulignant l'importance d'une modélisation réaliste des dépendances dans le cadre de la solvabilité et de l'allocation optimale du capital.

Table des matières

1	AXE I : Limites des Approches Classiques de la Dépendance	5
1.1	Définition et Fondements Formels de la Corrélation de Pearson (ρ)	5
1.2	Les Quatre Hypothèses Implicites de ρ	5
1.3	L'Insuffisance Fondamentale : ρ ne Détermine pas la Distribution Jointe . .	6
2	AXE II : Fondements Théoriques des Copules	7
2.1	Le Théorème de Sklar (1959) : Énoncé et Implications	7
2.2	La Copule comme Objet Mathématique	7
2.3	Le Principe de Séparation Structure / Marges	8
2.4	Les Mesures de Concorde : τ de Kendall et ρ_S de Spearman	8
2.5	Les Bornes de Fréchet-Hoeffding	9
3	AXE III : Familles de copules et leurs propriétés	10
3.1	Dépendance de queue	10
3.1.1	Définition formelle	10
3.2	Les copules elliptiques	11
3.2.1	Copule gaussienne	11
3.2.2	Copule de Student- t	11
3.3	Les copules archimédiennes	12
3.3.1	Copule de Clayton	13
3.3.2	Copule de Gumbel	13
3.3.3	Copule de Frank	14
3.4	Tableau récapitulatif des familles de copules	15
4	AXE IV : Estimation et sélection du modèle de copule	16
4.1	Les trois méthodes d'estimation	16
4.1.1	Méthode des moments — Estimation par τ de Kendall	16
4.1.2	Maximum de vraisemblance (MLE) — Estimation jointe	16

4.1.3	Méthode IFM — Inférence par les Fonctions Marginales	17
4.2	Sélection du modèle — Critères d'information	18
4.2.1	Critère d'Akaike (AIC)	18
4.2.2	Critère Bayésien de Schwarz (BIC)	19
4.3	Tests d'adéquation (<i>Goodness-of-Fit</i>)	19
4.3.1	Test de Cramér-von Mises	19
4.3.2	Inspection graphique — Copule empirique vs théorique	19
4.3.3	Procédure pratique de sélection	20
5	Application	21
5.1	Étape 1 : Description des Données	22
5.1.1	Sources	22
5.1.2	Portefeuille étudié	23
5.2	Étape 2 : Redressement Inflation	23
5.3	Étape 3 : Ajustement des Lois Marginales	24
5.3.1	Méthode	24
5.3.2	Résultats	24
5.4	Étape 4 : Analyse des Dépendances	26
5.4.1	Choix des mesures	26
5.4.2	Résultats : 14 paires significatives sur 28	26
5.5	Étape 5 : Transformation en Pseudo-Uniformes	27
5.6	Étape 6 : Sélection des Copules Bivariées	28
5.6.1	Familles de copules testées	28
5.6.2	Résultats de la sélection	28
5.7	Étape 7 : Vine Copule : Modèle Joint 8 Garanties	30
5.8	Étape 8 : Simulation Monte Carlo	31
5.9	Étape 9 : Besoins en Fonds Propres	31
5.9.1	Mesures de risque	31
5.9.2	Résultats	32

6	Résumé et Conclusions	33
6.1	Synthèse des résultats	33
6.2	Limites et perspectives	34
7	Références	35
A	Annexe : Code Python	36

1. AXE I : Limites des Approches Classiques de la Dépendance

La corrélation linéaire de Pearson constitue depuis plus d'un siècle l'outil de référence pour quantifier la relation entre deux variables aléatoires. Omniprésente dans la pratique statistique, financière et actuarielle, elle offre une mesure synthétique, facilement interprétable et simple à calculer. Cependant, une analyse rigoureuse révèle que cet indicateur repose sur des hypothèses implicites très restrictives, dont la méconnaissance peut conduire à des erreurs graves d'évaluation du risque.

1.1. Définition et Fondements Formels de la Corrélation de Pearson (ρ)

Le coefficient de corrélation linéaire de Pearson, noté $\rho(X, Y)$, est défini pour deux variables aléatoires X et Y de variances finies par :

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \cdot \sigma_Y}$$

Ce coefficient mesure l'intensité et le sens d'une relation linéaire entre deux variables. Ses valeurs limites constituent les cas extrêmes de la dépendance linéaire :

Valeur	Cas	Interprétation
$\rho = +1$	Comonotonie parfaite	$Y = aX + b$ avec $a > 0$ (relation linéaire croissante parfaite)
$\rho = 0$	Absence de lien linéaire	Attention : $\rho = 0$ n'implique PAS l'indépendance statistique !
$\rho = -1$	Contra-monotonie parfaite	$Y = aX + b$ avec $a < 0$ (relation linéaire décroissante parfaite)

1.2. Les Quatre Hypothèses Implicites de ρ

Le recours à la corrélation de Pearson engage, souvent implicitement, quatre hypothèses structurelles. La violation de l'une d'entre elles peut rendre cette mesure inadaptée ou trompeuse.

1. **Hypothèse de Linéarité :** La corrélation de Pearson ne capture exclusivement que la composante linéaire de la relation entre X et Y . Toute dépendance de nature non linéaire lui échappe totalement.

Exemple Illustratif

Exemple : Soit $X \sim \mathcal{N}(0, 1)$ et $Y = X^2$. Ces deux variables sont fonctionnellement dépendantes. Pourtant, par symétrie de la loi normale, $\mathbb{E}[X^3] = 0$, ce qui entraîne $\text{Cov}(X, X^2) = \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2] = 0$. On obtient donc $\rho(X, Y) = 0$. La corrélation nulle coexiste ici avec une dépendance fonctionnelle parfaite.

2. **Hypothèse d'Existence des Moments :** La définition de ρ exige que $\text{Var}(X) < +\infty$ et $\text{Var}(Y) < +\infty$. Cette condition est violée par certaines distributions à queues épaisses (Pareto avec $\alpha \leq 2$, lois stables non gaussiennes d'indice $\alpha < 2$, Cauchy). Dans ces cas, ρ n'est pas définie mathématiquement.
3. **Hypothèse d'Ellipticité :** ρ décrit exhaustivement la structure de dépendance si et seulement si la distribution est elliptique (gaussienne multivariée, Student multivariée). Hors de ce cadre, ρ est une description incomplète et potentiellement trompeuse.
4. **Non-invariance par Transformation Monotone :** $\rho(T(X), T(Y)) \neq \rho(X, Y)$ en général si T est strictement croissante. En revanche, les mesures de concordance ordinales (τ de Kendall, ρ_S de Spearman) sont invariantes par toute transformation strictement monotone croissante.

1.3. L'Insuffisance Fondamentale : ρ ne Détermine pas la Distribution Jointe

La limitation la plus profonde est la suivante : la donnée des distributions marginales F_X , F_Y et de leur corrélation ρ ne détermine **pas** de manière unique leur distribution jointe.

Résultat Fondamental

Si l'on fixe les distributions marginales F_X et F_Y ainsi que la valeur de $\rho(X, Y)$, il existe une infinité de distributions jointes $F(x, y)$ compatibles avec ces contraintes. La corrélation est donc une information nécessaire mais largement insuffisante pour caractériser la structure de dépendance.

Attention

Illusion de Diversification : Ignorer la structure réelle de dépendance conduit à une illusion de diversification qui disparaît précisément lors des crises financières. Les événements de corrélation extrême (co-crashes) ne peuvent être modélisés correctement par une simple valeur de ρ . La crise de 2008 illustre ce phénomène : les modèles fondés sur la copule gaussienne avaient gravement sous-estimé la probabilité de défauts simultanés dans les portefeuilles de CDO.

2. AXE II : Fondements Théoriques des Copules

Face aux limitations démontrées à l'Axe I, la théorie des copules offre un cadre mathématique rigoureux permettant de séparer et de modéliser indépendamment les comportements marginaux et la structure de dépendance d'un vecteur aléatoire.

2.1. Le Théorème de Sklar (1959) : Énoncé et Implications

Théorème 2.1 (Sklar, 1959). *Soit F une fonction de répartition jointe de dimension d , de marginales continues $F_1, \dots, F_d$. Il existe une copule $C : [0, 1]^d \rightarrow [0, 1]$, unique, telle que pour tout $(x_1, \dots, x_d) \in \mathbb{R}^d$:*

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$$

Réciproquement, toute copule C combinée à des marginales $F_1, \dots, F_d$ quelconques définit une distribution jointe valide via cette formule.

Ce théorème admet deux lectures complémentaires :

- **Sens direct (décomposition)** : Toute distribution jointe à marginales continues peut être décomposée de manière unique en ses marginales et une copule. La copule capture alors *uniquement* la structure de dépendance.
- **Sens réciproque (construction)** : Toute copule, combinée à des marginales quelconques, génère une distribution jointe valide. Cette modularité offre une liberté totale pour la construction de modèles multivariés.

2.2. La Copule comme Objet Mathématique

Formellement, une **copule de dimension d** est une fonction de répartition définie sur le cube unité $[0, 1]^d$ dont toutes les distributions marginales sont uniformes sur $[0, 1]$:

$$C : [0, 1]^d \rightarrow [0, 1] \quad \text{telle que} \quad C_i(u) = u \quad \forall u \in [0, 1]$$

L'expression de la copule à partir de la distribution jointe F est donnée par :

$$C(u_1, \dots, u_d) = F(F_1^{-1}(u_1), \dots, F_d^{-1}(u_d))$$

Cette représentation repose sur la *transformation de la probabilité intégrale* : $U_i = F_i(X_i) \sim \mathcal{U}[0, 1]$.

Factorisation de la Densité et Méthode IFM Lorsque F est absolument continue, la densité jointe se factorise :

$$f(x_1, \dots, x_d) = c(F_1(x_1), \dots, F_d(x_d)) \cdot \prod_{i=1}^d f_i(x_i)$$

où $c = \frac{\partial^d C}{\partial u_1 \dots \partial u_d}$ est la densité de la copule. Cette factorisation justifie la méthode **IFM** (*Inference Functions for Margins*), qui estime les paramètres marginaux et copule en deux étapes indépendantes.

2.3. Le Principe de Séparation Structure / Marges

L'apport conceptuel majeur réside dans la séparation formelle entre deux composantes distinctes :

Distributions Marginales $F_1, \dots, F_d$	Décrivent le comportement individuel de chaque variable (queues, asymétrie, moments). Choix libre : Gaussienne, Student t_ν , GEV, Lognormale, Pareto, Gamma...
La Copule C	Décrit exclusivement la structure de dépendance, indépendamment des marginales. Choix selon le contexte : Gaussienne (sans dépendance de queue), Student (queue symétrique), Clayton (queue inférieure), Gumbel (queue supérieure).

Remarque 2.2 (Invariance par Transformation Monotone). Si $(X_1, \dots, X_d)$ admet la copule C , et si $T_1, \dots, T_d$ sont des transformations strictement croissantes, alors $(T_1(X_1), \dots, T_d(X_d))$ admet la **même** copule C . La copule capture donc une propriété intrinsèque et invariante de la dépendance.

2.4. Les Mesures de Concordance : τ de Kendall et ρ_S de Spearman

Contrairement à ρ de Pearson, les mesures de concordance ordinales sont invariantes par transformations monotones croissantes et s'expriment directement comme des fonctionnelles de la copule.

1. **τ de Kendall** : Mesure la probabilité de concordance moins la probabilité de discordance pour deux tirages indépendants.

$$\tau(X, Y) = \mathbb{P}[(X_1 - X_2)(Y_1 - Y_2) > 0] - \mathbb{P}[(X_1 - X_2)(Y_1 - Y_2) < 0] = 4 \iint_{[0,1]^2} C(u, v) dC(u, v) - 1$$

2. ρ_S de Spearman : Corrélation de Pearson des rangs (appliquée aux variables uniformes $U_i = F_i(X_i)$).

$$\rho_S(X, Y) = 12 \iint_{[0,1]^2} C(u, v) du dv - 3$$

Critère	ρ de Pearson	τ de Kendall	ρ_S de Spearman
Invariance monotone	× Non	✓ Oui	✓ Oui
Fondé sur	Moments (Cov/Var)	Concordance / discordance	Rangs empiriques
Moments finis requis	× Oui (Var < ∞)	✓ Non	✓ Non
Fonctionnelle de la copule	× Non (en général)	✓ Oui	✓ Oui

2.5. Les Bornes de Fréchet-Hoeffding

Toute copule bivariable C est nécessairement encadrée par deux copules extrêmes :

$$W(u, v) \leq C(u, v) \leq M(u, v) \quad \forall (u, v) \in [0, 1]^2$$

$M(u, v) = \min(u, v)$	Borne supérieure — Comonotonie. X et Y sont comonotones. Tout choc affecte les deux variables dans le même sens. $\tau = \rho_S = \rho = 1$. Valide en toute dimension $d \geq 2$.
$\Pi(u, v) = u \cdot v$	Copule produit — Indépendance. X et Y sont stochastiquement indépendantes. $\tau = \rho_S = \rho = 0$. Toujours une copule valide.
$W(u, v) = \max(u + v - 1, 0)$	Borne inférieure — Contra-monotonie. $Y = g(X)$ avec g strictement décroissante. $\tau = \rho_S = \rho = -1$. Attention : W n'est PAS une copule valide en dimension $d \geq 3$.

Remarque 2.3 (Paradoxe en dimension $d \geq 3$). En dimension 3 ou plus, la borne inférieure W n'est pas atteignable simultanément pour toutes les paires. On ne peut pas avoir X_1 et X_2 contra-monotones, X_1 et X_3 contra-monotones, et X_2 et X_3 contra-monotones en même temps. Ce paradoxe illustre la complexité intrinsèque de la dépendance multivariée.

Résultat Fondamental

Application en gestion des risques (VaR) : Si $S = X_1 + \dots + X_d$ désigne la perte totale et $\alpha > 0.5$, les bornes de Fréchet-Hoeffding permettent d'encadrer la

Value-at-Risk sans connaître la copule exacte :

$$\text{VaR}_\alpha(S_W) \leq \text{VaR}_\alpha(S) \leq \text{VaR}_\alpha(S_M)$$

La borne supérieure est atteinte sous la copule comonotone M , représentant le scénario de pire cas. Ce résultat est fondamental en actuariat et en gestion des risques.

3. AXE III : Familles de copules et leurs propriétés

3.1. Dépendance de queue

3.1.1 Définition formelle

La **dépendance de queue** est une notion fondamentale pour évaluer si des événements extrêmes — sinistres catastrophiques, défauts simultanés, krachs boursiers — tendent à survenir conjointement. On distingue deux coefficients :

Soient X et Y deux variables aléatoires de fonctions de répartition F_X et F_Y .

— **Queue inférieure** :

$$\lambda_L = \lim_{u \rightarrow 0^+} \mathbb{P}(X \leq F_X^{-1}(u) \mid Y \leq F_Y^{-1}(u))$$

— **Queue supérieure** :

$$\lambda_U = \lim_{u \rightarrow 1^-} \mathbb{P}(X > F_X^{-1}(u) \mid Y > F_Y^{-1}(u))$$

- Si $\lambda = 0$: **indépendance asymptotique en queue** — les événements extrêmes ne coïncident pas.
- Si $\lambda > 0$: **dépendance en queue** — lorsque Y est extrême, X tend à l'être également.

Sur les marchés financiers, on observe empiriquement $\lambda_L > \lambda_U$: les crises sont plus contagieuses que les hausses. En réassurance, ignorer $\lambda_U > 0$ conduit à une sous-estimation systématique du capital requis pour les événements catastrophiques.

3.2. Les copules elliptiques

Les copules elliptiques héritent de la géométrie des lois elliptiques multivariées. Leur avantage principal est la **simplicité de paramétrage** : une matrice de corrélation Σ suffit. Elles sont par construction *symétriques* — la queue gauche et la queue droite se comportent identiquement.

3.2.1 Copule gaussienne

Soit Φ la fonction de répartition d'une loi $\mathcal{N}(0, 1)$ et Φ_Σ celle d'une loi gaussienne multivariée de matrice de corrélation Σ . La copule gaussienne de paramètre Σ est :

$$C_\Sigma^{\text{Gauss}}(u_1, \dots, u_d) = \Phi_\Sigma(\Phi^{-1}(u_1), \dots, \Phi^{-1}(u_d))$$

- (i) Paramétrée par la matrice de corrélation $\rho \in [-1, 1]$ (cas bivarié).
- (ii) **Symétrique** : les queues gauche et droite ont un comportement identique.
- (iii) **Aucune dépendance de queue** : $\lambda_L = \lambda_U = 0$.
- (iv) Cas particulier : $\rho = 0 \Rightarrow$ indépendance totale.
- (v) Cohérente avec la corrélation linéaire de Pearson.

Limite majeure

La copule gaussienne **sous-estime les risques extrêmes**. Son utilisation abusive dans les modèles CDO a été l'une des causes de la crise financière de 2008 (modèle de Li). Elle ne peut pas capturer les co-mouvements extrêmes observés lors des crises.

3.2.2 Copule de Student- t

Soit t_ν la fonction de répartition d'une loi de Student à ν degrés de liberté et $t_{\nu, \Sigma}$ celle d'une loi de Student multivariée de paramètres (ν, Σ) . La copule de Student est :

$$C_{\nu, \Sigma}^t(u_1, \dots, u_d) = t_{\nu, \Sigma}(t_\nu^{-1}(u_1), \dots, t_\nu^{-1}(u_d))$$

- (i) Paramètres : matrice de corrélation Σ et degrés de liberté $\nu > 0$.
- (ii) Capture les **dépendances extrêmes** grâce aux queues épaisses.
- (iii) **Dépendance de queue symétrique** : $\lambda_L = \lambda_U > 0$. Le coefficient vaut :

$$\lambda = 2\bar{t}_{\nu+1} \left(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right)$$

où $\bar{t}_{\nu+1} = 1 - t_{\nu+1}$.

- (iv) Plus ν est petit, plus les extrêmes sont dépendants.
- (v) Convergence : $\nu \rightarrow \infty \Rightarrow$ copule gaussienne.

Différence fondamentale : Gaussienne vs Student

Propriété	Gaussienne	Student- t
Dépendance de queue	$\lambda = 0$	$\lambda > 0$
Queues	Minces	Épaisses
Adaptation aux crises	Faible	Bonne
Paramètre additionnel	—	ν (ddl)

En assurance ou en finance, ignorer $\lambda > 0$ conduit à **sous-estimer le capital requis**.

3.3. Les copules archimédiennes

Les copules archimédiennes sont définies à partir d'une seule fonction scalaire φ , appelée **générateur**, ce qui les rend à la fois flexibles et analytiquement tractables.

Une copule C est dite *archimédienne* s'il existe une fonction $\varphi : [0, 1] \rightarrow [0, +\infty]$, continue, décroissante, convexe, avec $\varphi(1) = 0$, telle que :

$$C(u_1, \dots, u_d) = \varphi^{-1}(\varphi(u_1) + \dots + \varphi(u_d))$$

Le générateur φ détermine **entièrement** la structure de dépendance.

3.3.1 Copule de Clayton

Pour $\theta \geq 0$, le générateur est $\varphi(t) = t^{-\theta} - 1$. La copule s'écrit :

$$C_{\theta}^{\text{Cl}}(u, v) = \left(u^{-\theta} + v^{-\theta} - 1\right)^{-1/\theta}$$

- (i) Paramètre $\theta \geq 0$.
- (ii) **Forte dépendance en queue inférieure** : $\lambda_L = 2^{-1/\theta} > 0$.
- (iii) **Aucune dépendance en queue supérieure** : $\lambda_U = 0$.
- (iv) Cas limites : $\theta \rightarrow 0 \Rightarrow$ indépendance, $\theta \rightarrow \infty \Rightarrow$ comonotonie.
- (v) Lien avec le τ de Kendall :

$$\tau = \frac{\theta}{2 + \theta} \iff \hat{\theta} = \frac{2\hat{\tau}}{1 - \hat{\tau}}$$

La copule de Clayton est particulièrement adaptée à la modélisation des **sinistres conjoints** et des **catastrophes naturelles**, où les pertes extrêmes basses surviennent simultanément (ex. inondations affectant plusieurs lignes de métier).

3.3.2 Copule de Gumbel

Pour $\theta \geq 1$, le générateur est $\varphi(t) = (-\ln t)^{\theta}$. La copule s'écrit :

$$C_{\theta}^{\text{Gu}}(u, v) = \exp\left(-\left[(-\ln u)^{\theta} + (-\ln v)^{\theta}\right]^{1/\theta}\right)$$

Proposition 3.4: Propriétés de la copule de Gumbel

- (i) Paramètre $\theta \geq 1$.
- (ii) **Forte dépendance en queue supérieure** : $\lambda_U = 2 - 2^{1/\theta} > 0$.
- (iii) **Aucune dépendance en queue inférieure** : $\lambda_L = 0$.
- (iv) Cas limites : $\theta = 1 \Rightarrow$ indépendance, $\theta \rightarrow \infty \Rightarrow$ comonotonie.

(v) Lien avec le τ de Kendall :

$$\tau = 1 - \frac{1}{\theta} \iff \hat{\theta} = \frac{1}{1 - \hat{\tau}}$$

La copule de Gumbel modélise idéalement les situations où les **valeurs extrêmes hautes surviennent simultanément** : rendements extrêmes positifs en finance, ou sinistres catastrophiques multibranches (tempêtes, séismes) en réassurance.

3.3.3 Copule de Frank

Pour $\theta \in \mathbb{R} \setminus \{0\}$, le générateur est $\varphi(t) = -\ln\left(\frac{e^{-\theta t} - 1}{e^{-\theta} - 1}\right)$. La copule s'écrit :

$$C_{\theta}^{\text{Fr}}(u, v) = -\frac{1}{\theta} \ln\left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1}\right)$$

- (i) Paramètre $\theta \in \mathbb{R} \setminus \{0\}$.
- (ii) **Symétrique** : dépendance identique aux deux queues.
- (iii) **Aucune dépendance de queue** : $\lambda_L = \lambda_U = 0$.
- (iv) Cas limites : $\theta \rightarrow 0 \Rightarrow$ indépendance, $\theta \rightarrow +\infty \Rightarrow$ borne de Fréchet supérieure, $\theta \rightarrow -\infty \Rightarrow$ borne de Fréchet inférieure.
- (v) Seule copule archimédienne admettant une dépendance **négative**.

La copule de Frank constitue un **point de départ naturel** pour toute analyse exploratoire, car elle couvre un large spectre de dépendances (positive et négative) sans biais de queue. Elle sert de référence neutre pour tester l'hypothèse de symétrie.

3.4. Tableau récapitulatif des familles de copules

TABLE 1 – Comparaison des principales familles de copules

Famille	Paramètre	λ_L	λ_U	Symétrie	Usage typique
Gaussienne	$\rho \in (-1, 1)$	0	0	Oui	Diversification
Student- t	$\rho, \nu > 0$	> 0	> 0	Oui	Risques extrêmes
Clayton	$\theta \geq 0$	> 0	0	Non	Sinistres, catastrophes
Gumbel	$\theta \geq 1$	0	> 0	Non	Réassurance, extrêmes hauts
Frank	$\theta \in \mathbb{R} \setminus \{0\}$	0	0	Oui	Point de départ

Règle de sélection selon le contexte

- **Catastrophes naturelles** (tempête, dégâts des eaux) : dépendance de queue **supérieure** → **Gumbel**
- **Santé / Invalidité** : dépendance de queue **inférieure** → **Clayton**
- **Responsabilité civile / Protection juridique** : dépendance **symétrique** → **Gaussienne ou Frank**
- **Crises financières, CDO** : queues épaisses et dépendance symétrique → **Student- t**

4. AXE IV : Estimation et sélection du modèle de copule

4.1. Les trois méthodes d'estimation

4.1.1 Méthode des moments — Estimation par τ de Kendall

La méthode des moments est la plus rapide : on estime d'abord τ de Kendall ou ρ_S de Spearman sur les données empiriques, puis on inverse la relation analytique entre la mesure de concordance et le paramètre θ de la copule.

$$\text{Clayton : } \tau = \frac{\theta}{\theta + 2} \implies \hat{\theta} = \frac{2\hat{\tau}}{1 - \hat{\tau}} \quad (1)$$

$$\text{Gumbel : } \tau = 1 - \frac{1}{\theta} \implies \hat{\theta} = \frac{1}{1 - \hat{\tau}} \quad (2)$$

$$\text{Gaussienne : } \tau = \frac{2}{\pi} \arcsin(\rho) \implies \hat{\rho} = \sin\left(\frac{\pi\hat{\tau}}{2}\right) \quad (3)$$

- ✓ Rapide, robuste, sans hypothèse sur les marginales.
- ✓ Adapté aux données peu nombreuses et à l'exploration rapide.
- ✗ Moins efficace statistiquement que le MLE (variance plus grande).
- ✗ Limité à un paramètre scalaire (inadapté aux matrices Σ).

4.1.2 Maximum de vraisemblance (MLE) — Estimation jointe

Le MLE estime simultanément les paramètres des marginales et de la copule en maximisant la log-vraisemblance complète.

Définition 4.1: Log-vraisemblance d'un modèle à copule

Pour n observations $(x_1^{(k)}, \dots, x_d^{(k)})_{k=1}^n$, la log-vraisemblance complète est :

$$\ell(\boldsymbol{\theta}, \boldsymbol{\alpha}) = \sum_{k=1}^n \ln c\left(F_1(x_1^{(k)}; \alpha_1), \dots, F_d(x_d^{(k)}; \alpha_d); \boldsymbol{\theta}\right) + \sum_{i=1}^d \sum_{k=1}^n \ln f_i(x_i^{(k)}; \alpha_i)$$

où $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_d)$ sont les paramètres marginaux, $\boldsymbol{\theta}$ est le paramètre de la copule, et c est la densité de copule.

- ✓ Estimateur asymptotiquement efficace (variance minimale).
- ✓ Optimal quand les marginales sont bien spécifiées.
- ✗ Calcul lourd, particulièrement en grande dimension.
- ✗ Sensible à la mauvaise spécification des marginales.

4.1.3 Méthode IFM — Inférence par les Fonctions Marginales

L'IFM (*Inference Functions for Margins*) est la méthode de référence en actuariat et en finance quantitative. Elle repose sur une estimation en deux étapes indépendantes, exploitant la factorisation de la log-vraisemblance induite par la décomposition de Sklar.

Étape 1. Estimation des marginales : Pour chaque $i = 1, \dots, d$, estimer $\hat{\alpha}_i$ par MLE univarié :

$$\hat{\alpha}_i = \operatorname{argmax}_{\alpha_i} \sum_{k=1}^n \ln f_i(x_i^{(k)}; \alpha_i)$$

Étape 2. Transformation en pseudo-observations : Pour chaque observation, calculer les pseudo-uniformes :

$$\hat{u}_i^{(k)} = F_i(x_i^{(k)}; \hat{\alpha}_i), \quad i = 1, \dots, d, \quad k = 1, \dots, n$$

En pratique, on utilise souvent les **rangs empiriques** : $\hat{u}_i^{(k)} = r_i^{(k)} / (n + 1)$ (méthode CML).

Étape 3. Estimation du paramètre de copule : Maximiser la log-vraisemblance de la copule sur les pseudo-observations :

$$\hat{\boldsymbol{\theta}} = \operatorname{argmax}_{\boldsymbol{\theta}} \sum_{k=1}^n \ln c(\hat{u}_1^{(k)}, \dots, \hat{u}_d^{(k)}; \boldsymbol{\theta})$$

L'estimateur IFM $\hat{\boldsymbol{\theta}}_{\text{IFM}}$ est **consistant** et **asymptotiquement normal** :

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_{\text{IFM}} - \boldsymbol{\theta}_0) \xrightarrow{\mathcal{L}} \mathcal{N}(\mathbf{0}, \mathbf{V}_{\text{IFM}})$$

Il est légèrement moins efficace que le MLE complet, mais beaucoup plus robuste et computationnellement tractable, ce qui en fait le **choix de référence** en pratique.

Comparaison des trois méthodes d'estimation

Critère	Moments	MLE	IFM
Vitesse	Très rapide	Lente	Rapide
Efficacité statistique	Faible	Optimale	Bonne
Robustesse marginales	Haute	Faible	Haute
Dimension	$d = 2$	Toute	Toute
Usage typique	Exploration	Modèles confirmés	Référence

4.2. Sélection du modèle — Critères d'information

Une fois les paramètres estimés, il faut comparer les copules candidates sur la base de critères d'information pénalisant la complexité du modèle.

4.2.1 Critère d'Akaike (AIC)

$$\text{AIC} = -2\hat{\ell} + 2k$$

où $\hat{\ell}$ est la log-vraisemblance maximisée et k le nombre de paramètres. On sélectionne la copule avec le plus petit AIC.

L'AIC pénalise la complexité de façon modérée — il est préféré lorsque l'objectif est la **prédiction** ou lorsque la taille d'échantillon est petite.

4.2.2 Critère Bayésien de Schwarz (BIC)

$$\text{BIC} = -2\hat{\ell} + k \ln(n)$$

Le BIC pénalise plus sévèrement les modèles complexes et tend à sélectionner des modèles plus **parcimonieux**. Il est préféré pour les grands échantillons.

Différence ΔAIC	Niveau de support
0 – 2	Forte évidence pour le modèle alternatif
2 – 4	Évidence positive
4 – 7	Évidence considérable
> 10	Évidence décisive

4.3. Tests d'adéquation (*Goodness-of-Fit*)

Les critères AIC/BIC mesurent l'ajustement relatif entre copules candidates. Les tests d'adéquation évaluent l'ajustement *absolu* à un niveau de signification contrôlé.

4.3.1 Test de Cramér-von Mises

Soient C_n la copule empirique et C_θ la copule théorique estimée. La statistique de test est :

$$S_n = n \int_{[0,1]^d} [C_n(\mathbf{u}) - C_{\hat{\theta}}(\mathbf{u})]^2 dC_n(\mathbf{u}) = \sum_{k=1}^n [C_n(\hat{\mathbf{u}}^{(k)}) - C_{\hat{\theta}}(\hat{\mathbf{u}}^{(k)})]^2$$

- Une **valeur p élevée** indique un bon ajustement (on ne rejette pas $H_0 : C = C_\theta$).
- La distribution sous H_0 est simulée par bootstrap paramétrique.
- Bien adapté aux copules bivariées ; la puissance décroît en grande dimension.

4.3.2 Inspection graphique — Copule empirique vs théorique

L'inspection visuelle reste indispensable. Pour chaque paire (i, j) , on compare :

1. Le **nuage de pseudo-observations** $(\hat{u}_i^{(k)}, \hat{u}_j^{(k)})$ avec la densité théorique de la copule sélectionnée.
2. La **densité empirique** (heatmap $K \times K$) avec la densité $c_{\hat{\theta}}(u, v)$.

4.3.3 Procédure pratique de sélection

Procédure recommandée en 4 étapes

1. **Calculer τ de Kendall et ρ_S de Spearman** sur les données brutes — ces deux indicateurs permettent souvent d'éliminer d'emblée les familles inappropriées.
2. **Inspecter graphiquement** la copule empirique : une concentration dans le coin inférieur gauche pointe vers Clayton ; dans le coin supérieur droit vers Gumbel.
3. **Estimer par IFM** les paramètres de toutes les familles candidates et calculer l'AIC et le BIC.
4. **Valider** la copule retenue avec le test de Cramér-von Mises.

Synthèse : Axes III et IV

Points clés à retenir

AXE III — Familles de copules

- Les copules elliptiques (gaussienne, Student- t) sont paramétrées par une matrice de corrélation ; la Student- t capture en plus les dépendances extrêmes ($\lambda > 0$), absentes de la copule gaussienne.
- Les copules archimédiennes (Clayton, Gumbel, Frank) sont asymétriques et permettent de modéliser des dépendances de queue spécifiques : Clayton (queue inf.), Gumbel (queue sup.), Frank (symétrique).
- Le choix de la famille doit être guidé par la nature du risque modélisé, pas par la commodité mathématique.

AXE IV — Estimation et sélection

- La méthode IFM (estimation en deux étapes sur les pseudo-observations) constitue le compromis optimal entre efficacité et robustesse.
- L'AIC et le BIC permettent de comparer les copules candidates ; le test de Cramér-von Mises valide l'ajustement absolu.
- La règle pratique : commencer par τ de Kendall et l'inspection graphique, puis formaliser avec AIC/BIC et tests d'adéquation.

5. Application

Un assureur non-vie gère simultanément plusieurs branches d'activité : incendie, tempête, dommages, vol, responsabilité civile, etc. La question centrale de ce rapport est la suivante :

Si plusieurs branches subissent simultanément de gros sinistres, quel niveau de capital l'assureur doit-il détenir pour rester solvable ?

L'hypothèse d'indépendance entre branches — souvent retenue par simplicité — ignore le fait que des événements comme les tempêtes, les catastrophes naturelles ou les récessions économiques touchent plusieurs branches en même temps. Cette hypothèse conduit à une évaluation biaisée du capital nécessaire.

La **théorie des copules** offre un cadre rigoureux pour modéliser ces dépendances. Elle permet de séparer le comportement marginal de chaque branche de leur structure de

dépendance conjointe (théorème de Sklar, 1959).

La méthodologie mise en œuvre suit les étapes suivantes :

1. Chargement et description des données
2. Redressement inflation (mise en euros constants)
3. Ajustement des lois marginales par branche
4. Analyse des dépendances (Kendall τ , Spearman ρ)
5. Transformation en pseudo-uniformes
6. Sélection des copules bivariées par critère AIC
7. Modélisation jointe par Vine Copule (8 branches)
8. Simulation Monte Carlo (100 000 scénarios)
9. Calcul du besoin en fonds propres (VaR, TVaR)

5.1. Étape 1 : Description des Données

5.1.1 Sources

Les données proviennent du package `CASdatasets` (Dutang & Charpentier), combinant trois jeux de données d'un assureur non-vie français anonyme :

- `freclaimset3multi9207` : charges sinistres agrégées sur 6 garanties commerciales, par période de 3 jours, 1992–2006
- `freclaimset3fire9207` : 58 056 sinistres individuels incendie (gros sinistres), 1992–2007
- `freclaimset3dam9207` : 109 992 sinistres individuels dommages (gros sinistres), 1992–2007

Les trois sources sont agrégées par mois de survenance, puis fusionnées sur la période commune 1992–2006.

5.1.2 Portefeuille étudié

N°	Garantie	Charge moy. mensuelle (€)	Source
1	Incendie (total)	9 126 398	Multi
2	Tempête	2 026 957	Multi
3	Dommages (total)	1 756 852	Multi
4	Vol	855 707	Multi
5	RC (TPL)	343 446	Multi
6	Autres	883 753	Multi
7	Gros Incendies	22 952 499	Sinistres indiv.
8	Gros Dommages	5 482 897	Sinistres indiv.
Total		43 428 512	

TABLE 2 – Description du portefeuille — charges sinistres mensuelles moyennes en euros courants (1992–2006).

Résultat clé : 180 mois d’observations, 8 garanties, 28 paires à analyser. La garantie Gros Incendies représente la charge moyenne la plus élevée (22,9 M€/mois) en raison de la sévérité des sinistres industriels.




FIGURE 1 – Évolution mensuelle des charges sinistres par garantie (1992–2006). Les pics de Gros Incendies (cyan) et d’Incendie (rouge) sont visibles à plusieurs reprises, témoignant de la volatilité de ces branches.

5.2. Étape 2 : Redressement Inflation

Les charges sinistres ne sont pas directement comparables d’une année à l’autre en raison de l’inflation. Un redressement est appliqué pour ramener toutes les charges en **euros constants 2006** :

$$S_t^{\text{adj}} = S_t \times (1,02)^{2006-t} \quad (4)$$

Le taux de 2% par an est retenu comme approximation de l'inflation des coûts de sinistres sur la période.

Année d'origine	Facteur appliqué
1992	$\times 1,319$
1995	$\times 1,243$
1998	$\times 1,172$
2001	$\times 1,126$
2004	$\times 1,061$
2005	$\times 1,020$
2006	$\times 1,000$

TABLE 3 – Facteurs de redressement inflation (base 2006, taux 2%/an). Les données de 1992 sont majorées de 31,9% pour être comparables à 2006.

5.3. Étape 3 : Ajustement des Lois Marginales

5.3.1 Méthode

Pour chaque garantie, trois familles de distributions sont ajustées par maximum de vraisemblance (avec contrainte $\text{loc} = 0$) :

- **Lognormale** $\text{LN}(\mu, \sigma)$: adaptée aux distributions à queue épaisse droite, classique en assurance non-vie
- **Weibull** $W(c, \text{scale})$: flexible, capte différentes formes de queue
- **Gamma** $\Gamma(\alpha, \text{scale})$: appropriée pour les sommes de variables exponentielles

La sélection est effectuée par le critère AIC (Akaike Information Criterion) :

$$\text{AIC} = 2k - 2\hat{\ell} \quad (5)$$

où k est le nombre de paramètres et $\hat{\ell}$ la log-vraisemblance maximale. La qualité d'ajustement est validée par le test de Kolmogorov-Smirnov (KS).

5.3.2 Résultats

Garantie	Loi	AIC	AIC Weibull	AIC Gamma	KS p-val
Incendie (total)	Lognormale	6 159	6 185	6 182	0.748
Tempête	Lognormale	5 537	5 598	5 620	0.101
Dommages (total)	Lognormale	5 445	5 510	5 471	0.831
Vol	Lognormale	5 171	5 218	5 187	0.656
RC (TPL)	Lognormale	4 928	4 965	4 946	0.962
Autres	Lognormale	5 313	5 340	5 332	0.793
Gros Incendies	Gamma	6 356	6 364	6 354	0.885
Gros Dommages	Lognormale	5 689	5 770	5 705	0.664

TABLE 4 – Résultats de l’ajustement des lois marginales. AIC en gras = loi retenue. Toutes les lois retenues passent le test KS au seuil 5%.

Résultat clé : La loi **Lognormale** est retenue pour 7 garanties sur 8 grâce à sa capacité à modéliser l’asymétrie droite et les queues épaisses des charges sinistres. La garantie **Gros Incendies** suit une loi **Gamma**, reflétant la distribution plus régulière des grands sinistres agrégés mensuellement.




FIGURE 2 – Histogrammes des charges sinistres mensuelles ajustées à l’inflation et courbes des lois marginales retenues (en blanc). La loi Lognormale capture bien le pic de faible valeur et la queue droite étirée caractéristiques des données d’assurance.

5.4. Étape 4 : Analyse des Dépendances

5.4.1 Choix des mesures

La corrélation de Pearson n'est pas adaptée ici car elle suppose la normalité et la linéarité de la relation. Deux mesures de **concordance** sont utilisées à la place :

Tau de Kendall :

$$\hat{\tau} = \frac{2}{n(n-1)} \sum_{i < j} \text{sign}[(x_i - x_j)(y_i - y_j)] \quad (6)$$

Rho de Spearman :

$$\hat{\rho}_S = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)} \quad (7)$$

où d_i est la différence des rangs de la paire i .

Ces mesures sont invariantes par transformation monotone croissante et mesurent la comonotonie des rangs, indépendamment de la forme des distributions.

5.4.2 Résultats : 14 paires significatives sur 28

Paire	Kendall τ	p-value	Spearman ρ	
Tempête $\leftrightarrow$ Dommages (total)	0.2906	< 0.001	0.4202	✓
Incendie (total) $\leftrightarrow$ Autres	0.2478	< 0.001	0.3543	✓
Incendie (total) $\leftrightarrow$ Gros Incendies	0.2457	< 0.001	0.3589	✓
Dommages (total) $\leftrightarrow$ Gros Dommages	0.2175	< 0.001	0.3095	✓
Dommages (total) $\leftrightarrow$ Gros Incendies	0.2124	< 0.001	0.3200	✓
Dommages (total) $\leftrightarrow$ Autres	0.2088	< 0.001	0.3105	✓
Vol $\leftrightarrow$ Autres	0.1430	0.004	0.2268	✓
Autres $\leftrightarrow$ Gros Incendies	0.1405	0.005	0.2126	✓
Gros Incendies $\leftrightarrow$ Gros Dommages	0.1400	0.005	0.2045	✓
Dommages (total) $\leftrightarrow$ Vol	0.1255	0.012	0.1943	✓
Incendie (total) $\leftrightarrow$ RC (TPL)	0.1172	0.020	0.1775	✓
Incendie (total) $\leftrightarrow$ Dommages (total)	0.1141	0.023	0.1706	✓
Vol $\leftrightarrow$ RC (TPL)	0.1122	0.025	0.1637	✓
RC (TPL) $\leftrightarrow$ Autres	0.1032	0.040	0.1549	✓

TABLE 5 – Paires avec dépendance significative ($p < 5\%$), triées par τ de Kendall décroissant.

Résultat clé : 14 paires sur 28 présentent une dépendance positive significative. Les dépendances les plus fortes concernent les événements météorologiques (**Tempête/Dommages**, $\tau = 0.291$) et la relation entre portefeuille agrégé et gros sinistres individuels (**Incendie/Gros Incendies**, $\tau = 0.246$). Toutes les dépendances sont positives : les mauvaises années sont simultanées dans plusieurs branches.




FIGURE 3 – Matrice des τ de Kendall pour les 8 garanties (28 paires). Les valeurs en gras indiquent une dépendance significative ($|\tau| > 0.10$). La diagonale vaut 1 par définition. Les couleurs vertes indiquent les dépendances positives, les rouges les négatives.

5.5. Étape 5 : Transformation en Pseudo-Uniformes

Avant l'ajustement des copules, chaque variable est transformée en uniforme sur $[0, 1]$ par la méthode des rangs empiriques :

$$\hat{U}_{i,k} = \frac{\text{rang}(X_{i,k})}{n+1}, \quad i = 1, \dots, n, \quad k = 1, \dots, 8 \quad (8)$$

Cette transformation est dite *canonique* (méthode CML — Canonical Maximum Likelihood). Elle présente deux avantages :

- Elle ne suppose aucune forme paramétrique pour les marginales

- Elle rend l'estimation du paramètre de la copule indépendante des éventuelles erreurs de spécification des marginales

Caractéristique	Valeur
Dimension de $\hat{\mathbf{U}}$	(180×8)
Minimum	0.0055
Maximum	0.9945

TABLE 6 – Caractéristiques de la matrice des pseudo-uniformes.

5.6. Étape 6 : Sélection des Copules Bivariées

5.6.1 Familles de copules testées

Copule	λ_L	λ_U	Dép. négative	Caractéristique
Gumbel	0	> 0	Non	Dépendance de queue supérieure : extrêmes simultanés
Clayton	> 0	0	Non	Dépendance de queue inférieure : petites pertes jointes
Frank	0	0	Oui	Dépendance centrale symétrique, sans effet de queue
Gaussienne	0	0	Oui	Dépendance elliptique, sans effet de queue

TABLE 7 – Propriétés des familles de copules testées. λ_L et λ_U désignent les coefficients de dépendance de queue inférieure et supérieure respectivement.

5.6.2 Résultats de la sélection

La sélection est effectuée par critère AIC calculé sur les pseudo-uniformes (méthode CML). Seules les 14 paires significatives (étape 4) sont modélisées.

Paire	Copule	Param. $\hat{a}$	τ estimé
Incendie $\leftrightarrow$ Dommages	Clayton	0.282	0.123
Incendie $\leftrightarrow$ RC (TPL)	Frank	1.069	0.117
Incendie $\leftrightarrow$ Autres	Frank	2.387	0.251
Incendie $\leftrightarrow$ Gros Incendies	Gaussienne	0.391	0.256
Tempête $\leftrightarrow$ Dommages	Gumbel	1.404	0.288
Dommages $\leftrightarrow$ Vol	Clayton	0.294	0.128
Dommages $\leftrightarrow$ Autres	Frank	1.995	0.213
Dommages $\leftrightarrow$ Gros Incendies	Frank	1.958	0.210
Dommages $\leftrightarrow$ Gros Dommages	Gumbel	1.288	0.224
Vol $\leftrightarrow$ RC (TPL)	Gumbel	1.122	0.109
Vol $\leftrightarrow$ Autres	Frank	1.333	0.146
RC (TPL) $\leftrightarrow$ Autres	Indépendance	—	0.000
Autres $\leftrightarrow$ Gros Incendies	Frank	1.308	0.143
Gros Incendies $\leftrightarrow$ Gros Dommages	Gaussienne	0.222	0.143

TABLE 8 – Copules sélectionnées par critère AIC (méthode CML). En gras : la paire Tempête/Dommages, la plus forte dépendance de queue supérieure.

Résultat clé : La copule de **Gumbel** est retenue pour les paires Tempête/Dommages et Dommages/Gros Dommages, confirmant la présence d'une **dépendance de queue supérieure** : lors des événements climatiques extrêmes, ces branches subissent simultanément des pertes importantes. La copule de **Frank** domine pour 6 paires à dépendance centrale.




FIGURE 4 – Nuages de points dans l'espace copule (pseudo-uniformes) pour les 3 paires les plus dépendantes. La concentration de points dans le coin supérieur droit (Tempête/-Dommages) confirme visuellement la dépendance de queue supérieure justifiant le choix de la copule de Gumbel.




FIGURE 5 – Copule sélectionnée par paire significative avec sa log-vraisemblance. La longueur des barres mesure la qualité d’ajustement. La légende indique la famille par couleur : rouge = Gumbel, bleu = Clayton, vert = Frank, violet = Gaussienne.

5.7. Étape 7 : Vine Copule : Modèle Joint 8 Garanties

Pour capturer la dépendance jointe entre les 8 branches simultanément, une **Vine Copule** (ou copule en vigne) est ajustée. Cette approche décompose la densité jointe en un produit de copules bivariées conditionnelles :

$$f(x_1, \dots, x_8) = \prod_{k=1}^8 f_k(x_k) \times \prod_{\text{arbres}} c_{i,j|D}(F_{i|D}(x_i), F_{j|D}(x_j)) \quad (9)$$

Cette structure est particulièrement adaptée aux portefeuilles multi-branches car elle :

- Permet des copules différentes pour chaque paire
- Capte les dépendances asymétriques et non-elliptiques
- S’adapte à tout nombre de branches

Paramètre	Valeur
Nombre de garanties	8
Niveau de troncature	2
Log-vraisemblance	74.56

TABLE 9 – Résultats de l’ajustement de la Vine Copule.

Données : CASdatasets — Assureur français (1992–2006)

5.8. Étape 8 : Simulation Monte Carlo

100 000 scénarios mensuels sont simulés à partir de la Vine Copule ajustée. L'algorithme est le suivant :

1. Simuler $\tilde{\mathbf{U}} \in [0, 1]^8$ à partir de la Vine Copule
2. Inverser les marginales : $\tilde{X}_{i,k} = F_k^{-1}(\tilde{U}_{i,k})$
3. Calculer la charge agrégée mensuelle : $\tilde{S}_i = \sum_{k=1}^8 \tilde{X}_{i,k}$

Statistique	Valeur
Nombre de scénarios simulés	100 000
Charge totale mensuelle moyenne	49.89 M€
Écart-type mensuel	21.93 M€

TABLE 10 – Statistiques de la distribution simulée de la charge agrégée.

5.9. Étape 9 : Besoins en Fonds Propres

5.9.1 Mesures de risque

Le besoin en capital est évalué par deux mesures complémentaires.

Value at Risk (VaR) : perte maximale à un niveau de confiance α

$$\text{VaR}_\alpha(S) = \inf\{x : F_S(x) \geq \alpha\} \quad (10)$$

Tail Value at Risk (TVaR) : perte moyenne au-delà de la VaR

$$\text{TVaR}_\alpha(S) = \mathbb{E}[S \mid S \geq \text{VaR}_\alpha(S)] \quad (11)$$

La TVaR est plus conservative et plus informative que la VaR car elle tient compte de la sévérité des sinistres extrêmes.

Pour mesurer l'impact des dépendances, la VaR sous l'hypothèse d'indépendance est calculée comme la somme des VaR individuelles :

$$\text{VaR}_\alpha^{\text{indép}}(S) = \sum_{k=1}^8 \text{VaR}_\alpha(X_k) \quad (12)$$

Le **gain de diversification** quantifie la réduction de capital permise par la modélisation des dépendances :

$$\text{Gain}_\alpha = \frac{\text{VaR}_\alpha^{\text{indép}} - \text{VaR}_\alpha^{\text{copule}}}{\text{VaR}_\alpha^{\text{indép}}} \quad (13)$$

5.9.2 Résultats

Seuil α	VaR (M€)	TVaR (M€)	VaR indép. (M€)	Gain
90,0%	76.00	96.56	86.45	12,1%
95,0%	88.68	111.62	107.49	17,5%
99,0%	123.51	155.16	167.31	26,2%
99,5%	140.38	179.61	198.28	29,2%
99,9%	198.96	255.07	292.38	32,0%

TABLE 11 – Besoins en fonds propres mensuels (M€) par mesure de risque et niveau de confiance. Le gain de diversification est croissant avec α , ce qui reflète l'impact des dépendances sur les événements extrêmes.

Résultat clé : Supposer l'indépendance entre branches **surestime** le capital nécessaire de **12% à 32%** selon le niveau de confiance. À l'inverse, ignorer toute dépendance dans un modèle de risque agrégé conduirait à *sous-estimer* le capital réel. La modélisation par copules permet de quantifier précisément le juste besoin en capital.




FIGURE 6 – Distribution de la charge mensuelle agrégée simulée (100 000 scénarios). Les lignes pointillées indiquent les seuils VaR. La zone rouge correspond à la queue de distribution au-delà de la VaR à 99%.




FIGURE 7 – Comparaison des besoins en capital : VaR avec copule (bleu), TVaR avec copule (rouge) et VaR sous indépendance (gris). Les pourcentages en bleu indiquent le gain de diversification. Le gain augmente avec le niveau de confiance : les copules sont d’autant plus importantes pour les événements extrêmes rares.

6. Résumé et Conclusions




FIGURE 8 – Tableaux récapitulatifs des trois niveaux d’analyse : lois marginales (gauche), top 8 dépendances (centre), besoins en capital (droite).

6.1. Synthèse des résultats

- Lois marginales :** La loi Lognormale décrit les charges sinistres mensuelles pour 7 garanties sur 8 (KS p-value > 0.10 dans tous les cas). La garantie Gros Incendies suit une loi Gamma.

2. **Dépendances** : 14 paires sur 28 présentent une dépendance positive significative. Les dépendances les plus fortes correspondent à des causes communes identifiables : événements climatiques (Tempête/Dommages), sinistres de grande ampleur (Incendie/Gros Incendies, Dommages/Gros Dommages), ou effets de contagion économique (Vol/Autres).
3. **Structure de dépendance** : La copule de Gumbel est sélectionnée pour les paires à risque climatique, confirmant la présence d'une dépendance de queue supérieure — c'est-à-dire une probabilité plus forte de sinistres simultanément extrêmes que ne le prédirait la corrélation simple.
4. **Impact sur le capital** : Ignorer les dépendances entre branches conduit à une surestimation du capital nécessaire de 12% (VaR 90%) à 32% (VaR 99,9%). Ce résultat montre l'importance d'une modélisation réaliste des dépendances pour une allocation efficace du capital.

6.2. Limites et perspectives

- Le modèle ne prend pas en compte la réassurance, qui modifierait les distributions marginales et les dépendances observées.
- La saisonnalité n'est pas modélisée explicitement. Une décomposition saisonnière préalable renforcerait l'hypothèse d'i.i.d. des résidus.
- Le test du chi-deux bivarié (Cadoux, 2004) pourrait compléter le critère AIC pour la sélection des copules.
- Une analyse de sensibilité au choix de la copule (Gumbel vs Frank pour certaines paires proches) serait pertinente.

7. Références

- Dutang C., Charpentier A. (2024). *CASdatasets : Actuarial Datasets*. R package version 1.2.0. <https://dutangc.github.io/CASdatasets>
- Nelsen R. (1999). *An Introduction to Copulas*. Springer Lecture Notes in Statistics.
- Embrechts P., McNeil A., Straumann D. (1999). *Correlation and dependence in risk management : properties and pitfalls*. Département de Mathématiques, ETH Zurich.
- Genest C., Rivest L. (1993). *Statistical inference procedures for bivariate Archimedean copulas*. Journal of the American Statistical Association, 88(423), 1034–1043.
- Artzner P., Delbaen F., Eber J.-M., Heath D. (1999). *Coherent measures of risk*. Mathematical Finance, 9(3), 203–228.
- Sklar, A. (1959). *Fonctions de répartition à n dimensions et leurs marges*. Publications de l’Institut de Statistique de l’Université de Paris, 8, 229–231.
- Joe, H. (1997). *Multivariate Models and Dependence Concepts*. Chapman & Hall, London.
- Nelsen, R.B. (2006). *An Introduction to Copulas* (2nd ed.). Springer, New York.
- Li, D.X. (2000). On default correlation : A copula function approach. *Journal of Fixed Income*, 9(4), 43–54.
- Bedford, T. & Cooke, R.M. (2002). Vines — a new graphical model for dependent random variables. *Annals of Statistics*, 30(4), 1031–1068.
- Genest, C. & Favre, A.-C. (2007). Everything you always wanted to know about copula modeling but were afraid to ask. *Journal of Hydrologic Engineering*, 12(4), 347–368.
- Artzner, P., Delbaen, F., Eber, J.-M. & Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- Nelsen, R. B. (2006). *An Introduction to Copulas*. 2ème édition, Springer Series in Statistics.
- Joe, H. (2014). *Dependence Modeling with Copulas*. Chapman and Hall/CRC Monographs on Statistics and Applied Probability.
- Embrechts, P., McNeil, A., & Straumann, D. (2002). *Correlation and dependence in risk management : properties and pitfalls*. In Risk Management : Value at Risk and Beyond. Cambridge University Press.
- McNeil, A. J., Frey, R., & Embrechts, P. (2015). *Quantitative Risk Management : Concepts, Techniques and Tools*. Revised Edition, Princeton University Press.

A. Annexe : Code Python

```

1  """
2  Copula Dependency Modelling -- Non-Life Insurer (8 Lines of Business)
3  =====
4  Source data (CASdatasets package):
5      - freclaimset3multi9207 : 6 aggregate commercial lines (1992-2006)
6      - freclaimset3fire9207  : individual large fire claims
7      - freclaimset3dam9207   : individual large property damage claims
8
9  Output   : 180 months x 8 lines of business -> 28 pairs analysed
10 Method   : Cadoux & Loizeau (2004) -- IFM + AIC copula selection
11 Tools    : numpy, scipy, pyvinecopulib, matplotlib
12 """
13 import sys, io, os
14 sys.stdout = io.TextIOWrapper(sys.stdout.buffer, encoding='utf-8')
15
16 import numpy as np
17 import pandas as pd
18 from scipy import stats
19 from scipy.stats import kendalltau, spearmanr
20 import matplotlib
21 matplotlib.use('Agg')
22 import matplotlib.pyplot as plt
23 import matplotlib.gridspec as gridspec
24 import itertools, warnings
25 warnings.filterwarnings('ignore')
26 import pyvinecopulib as pv
27
28 np.random.seed(42)
29
30 # --- Paths (script directory) -----
31 SCRIPT_DIR = os.path.dirname(os.path.abspath(__file__))
32 CSV_PATH   = os.path.join(SCRIPT_DIR, "C:\\Users\\HP\\Downloads\\
33     monthly_claims_combined.csv")
34 OUT_PNG     = os.path.join(SCRIPT_DIR, r"C:\Users\HP\Downloads\
35     cadoux_v2_results.png")
36
37 # =====
38 # STEP 1 -- DATA LOADING
39 # =====
40 print("=" * 64)
41 print("ETAPE 1 -- DONNEES (8 garanties, assureur francais non-vie)")
42 print("=" * 64)

```

```

42 df = pd.read_csv(CSV_PATH)
43 df['Mois'] = pd.to_datetime(df['Mois'])
44 df = df.sort_values('Mois').reset_index(drop=True)
45
46 # Column names mapped to labels used throughout the analysis
47 GARANTIES = {
48     'Fire_Claim'      : 'Incendie (total)',
49     'HSS_Claim'       : 'Tempete',
50     'Damage_Claim'    : 'Dommages (total)',
51     'Thief_Claim'     : 'Vol',
52     'TPL_Claim'       : 'RC (TPL)',
53     'Other_Claim'     : 'Autres',
54     'LargeFire_Claim' : 'Gros Incendies',
55     'LargeDam_Claim'  : 'Gros Dommages',
56 }
57 cols = list(GARANTIES.keys())
58 labels = list(GARANTIES.values())
59
60 print(f"   Periode      : {df['Mois'].min().strftime('%Y-%m')} -> {df['Mois']
61       '.max().strftime('%Y-%m')}")
62 print(f"   Mois          : {len(df)}")
63 print(f"   Garanties      : {len(cols)} -> {len(cols)*(len(cols)-1)//2}
64       paires a analyser")
65 print(f"\n   Charge mensuelle moyenne (EUR) :")
66 for c, l in GARANTIES.items():
67     print(f"       {l:22s}: {df[c].mean():>15,.0f} EUR")
68
69 # =====
70 # STEP 2 -- INFLATION ADJUSTMENT
71 # All claims restated in constant 2006 euros at 2% per year
72 # =====
73 print("\n" + "=" * 64)
74 print("ETAPE 2 -- REDRESSEMENT INFLATION (2% / an, base 2006)")
75 print("=" * 64)
76
77 base_year = 2006
78 inflation = 0.02
79 df['annee'] = df['Mois'].dt.year
80 for c in cols:
81     df[c + '_adj'] = df[c] * (1 + inflation) ** (base_year - df['annee']
82     ])
83
84 cols_adj = [c + '_adj' for c in cols]
85 print(f"   Facteur 1992 : x{(1.02)**(base_year-1992):.3f} |   Facteur
86       2005 : x{(1.02)**(base_year-2005):.3f}")
87
88 # =====

```

```

85 # STEP 3 -- MARGINAL DISTRIBUTION FITTING
86 # Candidates : Lognormal, Weibull, Gamma (fitted by MLE, loc=0)
87 # Selection : lowest AIC; validated by Kolmogorov-Smirnov test
88 # =====
89 print("\n" + "=" * 64)
90 print("ETAPE 3 -- AJUSTEMENT LOIS MARGINALES")
91 print("=" * 64)
92
93 DIST = {'Lognormale': stats.lognorm,
94         'Weibull' : stats.weibull_min,
95         'Gamma' : stats.gamma}
96
97 best_fits = {}
98 summary_fits = []
99
100 for c, label in zip(cols_adj, labels):
101     x = df[c].values
102     res = {}
103     for dname, dist in DIST.items():
104         params = dist.fit(x, floc=0)
105         ll = np.sum(dist.logpdf(x, *params))
106         aic = 2*len(params) - 2*ll
107         ks, kp = stats.kstest(x, lambda v: dist.cdf(v, *params))
108         res[dname] = {'params': params, 'aic': aic, 'ks_p': kp}
109     best = min(res, key=lambda d: res[d]['aic'])
110     best_fits[c] = {'dist': best, 'params': res[best]['params']}
111     summary_fits.append({'Garantie': label, 'Loi retenue': best,
112                        'KS p-value': round(res[best]['ks_p'], 3)})
113     print(f" {label:22s} -> {best:12s} (KS p={res[best]['ks_p']:.3f})"
114           , end="")
115     print(f" [AIC: " + " | ".join(f"{d}={r['aic']:.0f}" for d,r in res.
116                                   items()) + "]"")
117
118 # =====
119 # STEP 4 -- DEPENDENCE ANALYSIS
120 # Kendall's tau and Spearman's rho for all 28 pairs
121 # Significance threshold :  $p < 0.05$ 
122 # =====
123 print("\n" + "=" * 64)
124 print("ETAPE 4 -- ANALYSE DES DEPENDANCES (28 paires)")
125 print("=" * 64)
126
127 X = df[cols_adj].values
128 pairs = list(itertools.combinations(range(len(cols_adj)), 2))
129 pair_labels = [f"{labels[i]} <-> {labels[j]}" for i,j in pairs]
130
131 dep_results = []

```

```

130 for (i,j), plabel in zip(pairs, pair_labels):
131     tau, p_tau = kendalltau(X[:,i], X[:,j])
132     rho, p_rho = spearmanr(X[:,i], X[:,j])
133     dep_results.append({'Paire'      : plabel,
134                        'Kendall t'  : round(tau,4),
135                        'p-val'      : round(p_tau,4),
136                        'Spearman r' : round(rho,4),
137                        'Sig.'       : '✓' if p_tau < 0.05 else '×'})
138
139 dep_df = pd.DataFrame(dep_results)
140 sig_df = dep_df[dep_df['Sig.']== '✓'].sort_values('Kendall t', ascending=
141     False)
142
143 print(f"\n Paires significatives : {len(sig_df)} / {len(dep_df)}\n")
144 print(sig_df.to_string(index=False))
145
146 # =====
147 # STEP 5 -- PSEUDO-UNIFORM TRANSFORMATION (CML method)
148 # Uik = rank(Xik) / (n+1) -- avoids boundary issues at 0 and 1
149 # =====
150 print("\n" + "=" * 64)
151 print("ETAPE 5 -- TRANSFORMATION EN PSEUDO-UNIFORMES")
152 print("=" * 64)
153
154 n = len(X)
155 U = np.column_stack([stats.rankdata(X[:,k]) / (n+1) for k in range(
156     X.shape[1])])
157 U_fort = np.asfortranarray(U)
158 print(f" U : {U.shape} range [{U.min():.4f}, {U.max():.4f}]")
159
160 # =====
161 # STEP 6 -- BIVARIATE COPULA SELECTION (significant pairs only)
162 # Families tested : Gumbel, Clayton, Frank, Gaussian, Independence
163 # Criterion : AIC on pseudo-observations (CML)
164 # =====
165 print("\n" + "=" * 64)
166 print("ETAPE 6 -- SELECTION DE COPULE (paires significatives)")
167 print("=" * 64)
168
169 fam_set = [pv.BicopFamily.gumbel, pv.BicopFamily.clayton,
170            pv.BicopFamily.frank, pv.BicopFamily.gaussian,
171            pv.BicopFamily.indep]
172
173 cop_results = []
174 sig_pairs = [(i,j) for i,j in pairs
175              if dep_df[dep_df['Paire']==f"{labels[i]} <-> {labels[j]}"]
176               ['Sig.'].values[0]== '✓']

```



```

174
175 for (i,j) in sig_pairs:
176     plabel = f"{labels[i]} <-> {labels[j]}"
177     u_pair = np.asfortranarray(U[:,[i,j]])
178     ctrl   = pv.FitControlsBicop(family_set=fam_set)
179     cop     = pv.Bicop(); cop.select(u_pair, ctrl)
180
181     # Compute AIC for each candidate family
182     scores = {}
183     for fam in fam_set[:-1]:
184         try:
185             c = pv.Bicop(family=fam); c.fit(u_pair)
186             ll = c.loglik(u_pair)
187             scores[fam.name] = -2*ll + 2*len(c.parameters.flatten())
188         except: pass
189
190     pv_val = round(float(cop.parameters.flatten()[0]),4) \
191             if len(cop.parameters.flatten()) > 0 else 'N/A'
192     cop_results.append({'Paire'      : plabel,
193                       'Copule'     : cop.family.name,
194                       'Parametre'  : pv_val,
195                       't copule'   : round(cop.tau,4),
196                       'Log-Lik'    : round(cop.loglik(u_pair),2)})
197
198     best_aic_fam = min(scores, key=scores.get) if scores else cop.family
199     .name
200     print(f"    {plabel}")
201     print(f"    -> {cop.family.name:10s}  t={cop.tau:.3f}  " +
202           " | ".join(f"{f}={a:.1f}" for f,a in sorted(scores.items(),
203               key=lambda x: x[1])))
204
205 cop_df = pd.DataFrame(cop_results)
206
207 # =====
208 # STEP 7 -- VINE COPULA (joint model, 8 lines of business)
209 # R-vine truncated at level 2 for parsimony
210 # =====
211 print("\n" + "=" * 64)
212 print("ETAPE 7 -- VINE COPULE (modele joint 8 garanties)")
213 print("=" * 64)
214
215 ctrl_vine = pv.FitControlsVinecop(family_set=fam_set, trunc_lvl=2)
216 vine      = pv.Vinecop(U.shape[1])
217 vine.select(U_fort, ctrl_vine)
218 print(f"    Log-vraisemblance : {vine.loglik(U_fort):.2f}")
219
220 # =====

```

```

219 # STEP 8 -- MONTE CARLO SIMULATION (N = 100 000 scenarios)
220 # 1. Simulate uniform samples from the fitted vine copula
221 # 2. Apply marginal quantile functions to recover claim amounts
222 # 3. Aggregate across all 8 lines of business
223 # =====
224 print("\n" + "=" * 64)
225 print("ETAPE 8 -- MONTE CARLO (N=100 000 scenarios)")
226 print("=" * 64)
227
228 N_SIM = 100_000
229 U_sim = vine.simulate(N_SIM, seeds=[42])
230 X_sim = np.zeros_like(U_sim)
231
232 for k, c in enumerate(cols_adj):
233     dn, par = best_fits[c]['dist'], best_fits[c]['params']
234     X_sim[:,k] = DISTS[dn].ppf(np.clip(U_sim[:,k], 1e-6, 1-1e-6), *par)
235
236 total = X_sim.sum(axis=1)
237 print(f" Monthly aggregate -- mean : {total.mean()/1e6:,.2f} M EUR "
238       f"std : {total.std()/1e6:,.2f} M EUR")
239
240 # =====
241 # STEP 9 -- CAPITAL REQUIREMENTS (VaR and TVaR)
242 # Diversification gain = (VaR_indep - VaR_copula) / VaR_indep
243 # =====
244 print("\n" + "=" * 64)
245 print("ETAPE 9 -- BESOINS EN FONDS PROPRES")
246 print("=" * 64)
247
248 levels = [0.90, 0.95, 0.99, 0.995, 0.999]
249 cap_results = []
250 for alpha in levels:
251     var = np.quantile(total, alpha)
252     tvar = total[total >= var].mean()
253     # Independence benchmark: sum of individual VaRs (upper Frechet
254     # bound)
255     indep = sum(np.quantile(X_sim[:,k], alpha) for k in range(X_sim.
256     shape[1]))
257     div = (indep - var) / indep * 100
258     cap_results.append({'Seuil' : f"{alpha*100:.1f}%",
259     'VaR (M EUR)' : round(var/1e6, 2),
260     'TVaR (M EUR)' : round(tvar/1e6, 2),
261     'VaR indep.(M EUR)': round(indep/1e6, 2),
262     'Gain diversif.': f"{div:.1f}%"})
263
264 cap_df = pd.DataFrame(cap_results)
265 print("\n" + cap_df.to_string(index=False))

```

```

264
265 # =====
266 # STEP 10 -- VISUALISATIONS (saved to OUT_PNG)
267 # Layout : 4 rows x 3 columns
268 #   Row 0 : monthly time series (all 8 lines)
269 #   Row 1 : marginal histograms with fitted curves (3 selected lines)
270 #   Row 2 : Kendall tau heatmap (8x8) + copula bar chart
271 #   Row 3 : aggregate loss distribution + VaR/TVaR comparison
272 # =====
273 print("\n" + "=" * 64)
274 print("ETAPE 10 -- VISUALISATIONS")
275 print("=" * 64)
276
277 # Dark theme colour palette
278 DARK = '#0f1117'; PANEL = '#1a1d27'; TEXT = '#e0e0e0'; GRID = '#2a2d3a'
279 ACC8 = ['#e74c3c', '#e67e22', '#f1c40f', '#2ecc71', '#3498db', '#9b59b6', '#1
      abc9c', '#e91e8c']
280
281 fig = plt.figure(figsize=(24, 28))
282 fig.patch.set_facecolor(DARK)
283 gs = gridspec.GridSpec(4, 3, figure=fig, hspace=0.45, wspace=0.35)
284
285 # --- Row 0 : monthly time series ---
286 ax_ts = fig.add_subplot(gs[0, :])
287 ax_ts.set_facecolor(PANEL)
288 for k, (c, label, color) in enumerate(zip(cols_adj, labels, ACC8)):
289     ax_ts.plot(df['Mois'], df[c]/1e6, color=color, lw=1.2, alpha=0.8,
        label=label)
290 ax_ts.set_title('Charges sinistres mensuelles -- 8 garanties -- Assureur
      francais (1992-2006)',
        color=TEXT, fontsize=12, fontweight='bold')
291 ax_ts.set_ylabel('Millions EUR', color=TEXT)
292 ax_ts.tick_params(colors=TEXT)
293 ax_ts.legend(fontsize=7, facecolor=PANEL, labelcolor=TEXT, ncol=8, loc='
      upper left')
294 for sp in ax_ts.spines.values(): sp.set_color(GRID)
295
296
297 # --- Row 1 : marginal histograms (Fire, Storm, Large Fire) ---
298 for idx, k in enumerate([0, 1, 6]):
299     ax = fig.add_subplot(gs[1, idx]); ax.set_facecolor(PANEL)
300     c = cols_adj[k]; label = labels[k]
301     x = df[c].values
302     ax.hist(x/1e6, bins=30, density=True, color=ACC8[k], alpha=0.6,
        edgecolor='none')
303     xr = np.linspace(x.min(), np.percentile(x, 99), 300)
304     dn = best_fits[c]['dist']; par = best_fits[c]['params']

```

```

305     ax.plot(xr/1e6, DISTS[dn].pdf(xr, *par)*1e6, color='white', lw=2,
           label=dn)
306     ax.set_title(f'{{label}}\n({dn}}', color=TEXT, fontsize=10, fontweight
           ='bold')
307     ax.set_xlabel('M EUR / mois', color=TEXT, fontsize=8)
308     ax.tick_params(colors=TEXT, labels=8)
309     ax.legend(fontsize=8, facecolor=PANEL, labelcolor=TEXT)
310     for sp in ax.spines.values(): sp.set_color(GRID)
311
312 # --- Row 2 left : Kendall tau heatmap (8x8) ---
313 ax_h = fig.add_subplot(gs[2, :2]); ax_h.set_facecolor(PANEL)
314 tau_mat = np.eye(len(labels))
315 for (i,j), plabel in zip(pairs, pair_labels):
316     row = dep_df[dep_df['Paire']==plabel]
317     if len(row):
318         v = float(row['Kendall t'].values[0])
319         tau_mat[i,j] = tau_mat[j,i] = v
320 im = ax_h.imshow(tau_mat, cmap='RdYlGn', vmin=-0.2, vmax=0.6, aspect='
           auto')
321 short = ['Incend.', 'Tempete', 'Dommag.', 'Vol', 'RC', 'Autres', 'Gros Inc.', '
           Gros Dam.']
322 ax_h.set_xticks(range(8)); ax_h.set_xticklabels(short, color=TEXT,
           fontsize=7, rotation=35)
323 ax_h.set_yticks(range(8)); ax_h.set_yticklabels(short, color=TEXT,
           fontsize=7)
324 for ii in range(8):
325     for jj in range(8):
326         ax_h.text(jj, ii, f'{{tau_mat[ii,jj]:.2f}}', ha='center', va='
           center',
327                 color='black', fontsize=7, fontweight='bold')
328 ax_h.set_title('Matrice Kendall tau -- 8 garanties (28 paires)', color=
           TEXT,
329                 fontsize=11, fontweight='bold')
330 plt.colorbar(im, ax=ax_h).ax.yaxis.set_tick_params(color=TEXT,
           labelcolor=TEXT)
331 for sp in ax_h.spines.values(): sp.set_color(GRID)
332
333 # --- Row 2 right : selected copula per pair (horizontal bar chart) ---
334 ax_c = fig.add_subplot(gs[2, 2]); ax_c.set_facecolor(PANEL)
335 fmap = {'gumbel': '#e74c3c', 'clayton': '#3498db', 'frank': '#2ecc71',
336         'gaussian': '#9b59b6', 'indep': '#95a5a6'}
337 short_p = [p.replace('Incendie (total)', 'Incend.').replace('Dommages (
           total)', 'Dommag.')
338             .replace('Tempete', 'Temp.').replace('Gros Incendies', '
           GrosInc.')
339             .replace('Gros Dommages', 'GrosDam.').replace('RC (TPL)', 'RC'
           ) for p in cop_df['Paire']]

```

```

340 bc = [fmap.get(f.lower(), '#aaa') for f in cop_df['Copule']]
341 bars = ax_c.barh(range(len(cop_df)), cop_df['Log-Lik'], color=bc,
342                 edgecolor='none', height=0.6)
343 ax_c.set_yticks(range(len(cop_df)))
344 ax_c.set_yticklabels(short_p, color=TEXT, fontsize=6)
345 for bar, fname in zip(bars, cop_df['Copule']):
346     w = bar.get_width()
347     ax_c.text(max(w*0.5, 0.3), bar.get_y()+bar.get_height()/2,
348              fname.capitalize(), ha='center', va='center', color='white',
349              fontsize=7, fontweight='bold')
350 ax_c.set_title('Copule selectionnee\npar paire (Log-Lik)', color=TEXT,
351               fontsize=10, fontweight='bold')
352 ax_c.set_xlabel('Log-Lik', color=TEXT, fontsize=9)
353 ax_c.tick_params(colors=TEXT, labelsize=6)
354 for sp in ax_c.spines.values(): sp.set_color(GRID)
355
356 # --- Row 3 left : aggregate loss distribution with VaR thresholds ---
357 ax_l = fig.add_subplot(gs[3, :2]); ax_l.set_facecolor(PANEL)
358 pct = np.percentile(total, 99.5)
359 ax_l.hist(total[total<=pct]/1e6, bins=120, density=True,
360          color='#6c8ebf', alpha=0.7, edgecolor='none')
361 for alpha_v, cv, res in zip(levels,
362                             ['#f39c12', '#e67e22', '#e74c3c', '#c0392b', '#922b21'], cap_results):
363     v = res['VaR (M EUR)']
364     if v <= pct/1e6:
365         ax_l.axvline(v, color=cv, lw=2, ls='--',
366                    label=f"VaR {res['Seuil']} = {v:.1f} M EUR")
367 ax_l.set_title('Distribution charge agregée mensuelle (8 garanties) --
368              Seuils VaR',
369              color=TEXT, fontsize=11, fontweight='bold')
370 ax_l.set_xlabel('Charge totale mensuelle (M EUR)', color=TEXT)
371 ax_l.set_ylabel('Densité', color=TEXT)
372 ax_l.tick_params(colors=TEXT)
373 ax_l.legend(fontsize=8, facecolor=PANEL, labelcolor=TEXT, ncol=2, loc='
374             upper right')
375 for sp in ax_l.spines.values(): sp.set_color(GRID)
376
377 # --- Row 3 right : VaR vs TVaR vs independence benchmark ---
378 ax_k = fig.add_subplot(gs[3, 2]); ax_k.set_facecolor(PANEL)
379 xp = np.arange(len(levels)); w = 0.25
380 ax_k.bar(xp-w, [r['VaR (M EUR)'] for r in cap_results], w, color='
381             #3498db', label='VaR (copule)', alpha=0.9)
382 ax_k.bar(xp, [r['TVaR (M EUR)'] for r in cap_results], w, color='
383             #e74c3c', label='TVaR (copule)', alpha=0.9)
384 ax_k.bar(xp+w, [r['VaR indep.(M EUR)'] for r in cap_results], w, color='
385             #95a5a6', label='VaR (indep.)', alpha=0.9)
386 ax_k.set_xticks(xp)

```

```

379 ax_k.set_xticklabels([r['Seuil'] for r in cap_results], color=TEXT,
    fontsize=8)
380 ax_k.set_title('VaR vs TVaR vs\nIndépendance', color=TEXT, fontsize=10,
    fontweight='bold')
381 ax_k.set_ylabel('M EUR / mois', color=TEXT, fontsize=9)
382 ax_k.tick_params(colors=TEXT, labels=8)
383 ax_k.legend(fontsize=7, facecolor=PANEL, labelcolor=TEXT)
384 for sp in ax_k.spines.values(): sp.set_color(GRID)
385
386 fig.suptitle('Copulas & Dependencies -- Cadoux (2004) methodology --
    Version 2\n'
    '8 lines of business | 180 months | freclaimset3multi9207 +
    fire9207 + dam9207',
    color=TEXT, fontsize=13, fontweight='bold', y=0.98)
389
390 plt.savefig(OUT_PNG, dpi=150, bbox_inches='tight', facecolor=DARK)
391 print(f" Figure saved : {OUT_PNG}")
392
393 # =====
394 # FINAL SUMMARY
395 # =====
396 print("\n" + "=" * 64)
397 print("RESUME FINAL")
398 print("=" * 64)
399 print(f"\n Mois : {len(df)} | Garanties : {len(cols)} | Paires : {
    len(pairs)}")
400 print(f" Paires significatives : {len(sig_df)}")
401 print("\n-- Marginal distributions --")
402 for c, l in zip(cols_adj, labels):
403     print(f" {l:22s} -> {best_fits[c]['dist']}")
404 print("\n-- Significant dependencies --")
405 print(sig_df.to_string(index=False))
406 print("\n-- Selected copulas --")
407 print(cop_df[['Paire', 'Copule', 'Parametre', 't copule']].to_string(index=
    False))
408 print("\n-- Capital requirements --")
409 print(cap_df.to_string(index=False))
410 print("\n[OK] Pipeline Cadoux v2 complete.")

1 """
2 Visualisations individuelles -- Methodologie Cadoux (2004)
3 =====
4 Genere chaque graphique separement dans le meme dossier.
5 Fichier requis : monthly_claims_combined.csv
6 """
7 import sys, io, os, itertools, warnings
8 sys.stdout = io.TextIOWrapper(sys.stdout.buffer, encoding='utf-8')

```

```

9 warnings.filterwarnings('ignore')
10
11 import numpy as np
12 import pandas as pd
13 from scipy import stats
14 from scipy.stats import kendalltau, spearmanr
15 import matplotlib
16 matplotlib.use('Agg')
17 import matplotlib.pyplot as plt
18 import matplotlib.gridspec as gridspec
19 import pyvinecopulib as pv
20
21 # -- Chemins -----
22 SCRIPT_DIR = os.path.dirname(os.path.abspath(__file__))
23 CSV_PATH = os.path.join(SCRIPT_DIR, r"C:\Users\HP\Downloads\
    monthly_claims_combined.csv")
24
25 # -- Couleurs & style -----
26 DARK = '#0f1117'
27 PANEL = '#1a1d27'
28 TEXT = '#e0e0e0'
29 GRID = '#2a2d3a'
30 ACC8 = ['#e74c3c', '#e67e22', '#f1c40f', '#2ecc71', '#3498db', '#9b59b6', '#1
    abc9c', '#e91e8c']
31
32 np.random.seed(42)
33
34 # =====
35 # PREPARATION DES DONNEES (commune a toutes les figures)
36 # =====
37 print("Chargement et preparation des donnees...")
38
39 df = pd.read_csv(CSV_PATH)
40 df['Mois'] = pd.to_datetime(df['Mois'])
41 df = df.sort_values('Mois').reset_index(drop=True)
42
43 GARANTIES = {
44     'Fire_Claim' : 'Incendie (total)',
45     'HSS_Claim' : 'Tempete',
46     'Damage_Claim' : 'Dommages (total)',
47     'Thief_Claim' : 'Vol',
48     'TPL_Claim' : 'RC (TPL)',
49     'Other_Claim' : 'Autres',
50     'LargeFire_Claim' : 'Gros Incendies',
51     'LargeDam_Claim' : 'Gros Dommages',
52 }
53 cols = list(GARANTIES.keys())

```

```

54 labels = list(GARANTIES.values())
55 SHORT = ['Incend.', 'Tempete', 'Dommag.', 'Vol', 'RC', 'Autres', 'Gros Inc.',
56          'Gros Dam.']
57
58 # Redressement inflation
59 base_year = 2006
60 df['annee'] = df['Mois'].dt.year
61 for c in cols:
62     df[c+'_adj'] = df[c] * (1.02)**(base_year - df['annee'])
63 cols_adj = [c+'_adj' for c in cols]
64
65 # Lois marginales
66 DIST = {'Lognormale': stats.lognorm,
67         'Weibull' : stats.weibull_min,
68         'Gamma' : stats.gamma}
69 best_fits = {}
70 for c, label in zip(cols_adj, labels):
71     x = df[c].values
72     res = {}
73     for dname, dist in DIST.items():
74         params = dist.fit(x, floc=0)
75         ll = np.sum(dist.logpdf(x, *params))
76         res[dname] = {'params': params, 'aic': 2*len(params)-2*ll}
77     best = min(res, key=lambda d: res[d]['aic'])
78     best_fits[c] = {'dist': best, 'params': res[best]['params']}
79
80 # Dependances
81 X = df[cols_adj].values
82 pairs = list(itertools.combinations(range(len(cols_adj)), 2))
83 pair_labels = [f"{labels[i]} <-> {labels[j]}" for i,j in pairs]
84 dep_results = []
85 for (i,j), plabel in zip(pairs, pair_labels):
86     tau, p_tau = kendalltau(X[:,i], X[:,j])
87     rho, _ = spearmanr(X[:,i], X[:,j])
88     dep_results.append({'Paire': plabel, 'Kendall tau': round(tau,4),
89                       'p-val': round(p_tau,4), 'Spearman rho': round(
90                           rho,4),
91                       'Sig.': '[OK]' if p_tau < 0.05 else '[NO]'})
92
93 dep_df = pd.DataFrame(dep_results)
94 sig_df = dep_df[dep_df['Sig.']== '[OK]'].sort_values('Kendall tau',
95             ascending=False)
96
97 # Pseudo-uniformes
98 n = len(X)
99 U = np.column_stack([stats.rankdata(X[:,k])/(n+1) for k in range(X.shape
100             [1])])
101 U_fort = np.asfortranarray(U)

```



```

97
98 # Copules
99 fam_set = [pv.BicopFamily.gumbel, pv.BicopFamily.clayton,
100            pv.BicopFamily.frank,  pv.BicopFamily.gaussian,
101            pv.BicopFamily.indep]
102 cop_results = []
103 sig_pairs = [(i,j) for i,j in pairs
104              if dep_df[dep_df['Paire']==f"{labels[i]} <-> {labels[j]}"]['Sig.'].values[0]=='[OK]']
105 for (i,j) in sig_pairs:
106     plabel = f"{labels[i]} <-> {labels[j]}"
107     u_pair = np.asfortranarray(U[:,[i,j]])
108     cop = pv.Bicop(); cop.select(u_pair, pv.FitControlsBicop(
109         family_set=fam_set))
110     pv_val = round(float(cop.parameters.flatten()[0]),4) \
111              if len(cop.parameters.flatten())>0 else 'N/A'
112     cop_results.append({'Paire': plabel, 'Copule': cop.family.name,
113                       'Parametre': pv_val, 'tau copule': round(cop.tau
114                        ,4),
115                       'Log-Lik': round(cop.loglik(u_pair),2)})
116 cop_df = pd.DataFrame(cop_results)
117
118 # Vine + Monte Carlo
119 ctrl_vine = pv.FitControlsVinecop(family_set=fam_set, trunc_lvl=2)
120 vine = pv.Vinecop(U.shape[1]); vine.select(U_for, ctrl_vine)
121 N_SIM = 100_000
122 U_sim = vine.simulate(N_SIM, seeds=[42])
123 X_sim = np.zeros_like(U_sim)
124 for k, c in enumerate(cols_adj):
125     dn, par = best_fits[c]['dist'], best_fits[c]['params']
126     X_sim[:,k] = DISTS[dn].ppf(np.clip(U_sim[:,k],1e-6,1-1e-6), *par)
127 total = X_sim.sum(axis=1)
128
129 # Capital
130 levels = [0.90, 0.95, 0.99, 0.995, 0.999]
131 cap_results = []
132 for alpha in levels:
133     var = np.quantile(total, alpha)
134     tvar = total[total >= var].mean()
135     indep = sum(np.quantile(X_sim[:,k], alpha) for k in range(X_sim.
136                        shape[1]))
137     div = (indep - var)/indep*100
138     cap_results.append({'Seuil': f"{alpha*100:.1f}%",
139                       'VaR': var, 'TVaR': tvar,
140                       'VaR_indep': indep, 'Div': div})
141
142 print("Donnees pretes. Generation des figures...\n")

```

```

140
141 # =====
142 # FIGURE 1 -- Series temporelles mensuelles
143 # =====
144 def fig1_series_temporelles():
145     fig, ax = plt.subplots(figsize=(18, 6))
146     fig.patch.set_facecolor(DARK); ax.set_facecolor(PANEL)
147
148     for k, (c, label, color) in enumerate(zip(cols_adj, labels, ACC8)):
149         ax.plot(df['Mois'], df[c]/1e6, color=color, lw=1.3,
150               alpha=0.85, label=label)
151
152     ax.set_title('Charges sinistres mensuelles par garantie\nAssureur
153                 francais non-vie -- 1992--2006',
154                 color=TEXT, fontsize=13, fontweight='bold', pad=12)
155     ax.set_ylabel('Millions EUR', color=TEXT, fontsize=11)
156     ax.set_xlabel('Date', color=TEXT, fontsize=11)
157     ax.tick_params(colors=TEXT)
158     ax.legend(fontsize=8, facecolor=PANEL, labelcolor=TEXT,
159             ncol=4, loc='upper right', framealpha=0.8)
160     for sp in ax.spines.values(): sp.set_color(GRID)
161     ax.grid(axis='y', color=GRID, alpha=0.4, lw=0.5)
162
163     path = os.path.join(Script_DIR, 'fig1_series_temporelles.png')
164     plt.tight_layout()
165     plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
166     plt.close()
167     print(f" [OK] fig1_series_temporelles.png")
168
169 # =====
170 # FIGURE 2 -- Distributions marginales (8 histogrammes)
171 # =====
172 def fig2_marginales():
173     fig, axes = plt.subplots(2, 4, figsize=(22, 10))
174     fig.patch.set_facecolor(DARK)
175     axes = axes.flatten()
176
177     for k, (c, label, color) in enumerate(zip(cols_adj, labels, ACC8)):
178         ax = axes[k]; ax.set_facecolor(PANEL)
179         x = df[c].values
180         ax.hist(x/1e6, bins=35, density=True, color=color,
181               alpha=0.65, edgecolor='none')
182         xr = np.linspace(x.min(), np.percentile(x,99), 300)
183         dn = best_fits[c]['dist']; par = best_fits[c]['params']
184         ax.plot(xr/1e6, DISTS[dn].pdf(xr,*par)*1e6,
185               color='white', lw=2.5, label=dn)
186         ax.set_title(f'{{label}}\n({dn})', color=TEXT,

```

```

186         fontsize=10, fontweight='bold')
187     ax.set_xlabel('MEUR / mois', color=TEXT, fontsize=9)
188     ax.set_ylabel('Densite', color=TEXT, fontsize=9)
189     ax.tick_params(colors=TEXT, labels=8)
190     ax.legend(fontsize=8, facecolor=PANEL, labelcolor=TEXT)
191     for sp in ax.spines.values(): sp.set_color(GRID)
192
193     fig.suptitle('Ajustement des lois marginales -- 8 garanties',
194                 color=TEXT, fontsize=14, fontweight='bold', y=1.01)
195     path = os.path.join(Script_DIR, 'fig2_marginales.png')
196     plt.tight_layout()
197     plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
198     plt.close()
199     print(f" [OK] fig2_marginales.png")
200
201 # =====
202 # FIGURE 3 -- Matrice Kendall tau (heatmap 8x8)
203 # =====
204 def fig3_heatmap_kendall():
205     fig, ax = plt.subplots(figsize=(10, 8))
206     fig.patch.set_facecolor(DARK); ax.set_facecolor(PANEL)
207
208     tau_mat = np.eye(len(labels))
209     for (i,j), plabel in zip(pairs, pair_labels):
210         row = dep_df[dep_df['Paire']==plabel]
211         if len(row):
212             v = float(row['Kendall tau'].values[0])
213             tau_mat[i,j] = tau_mat[j,i] = v
214
215     im = ax.imshow(tau_mat, cmap='RdYlGn', vmin=-0.2, vmax=0.6, aspect='
216         auto')
217     ax.set_xticks(range(8))
218     ax.set_xticklabels(SHORT, color=TEXT, fontsize=9, rotation=35, ha='
219         right')
220     ax.set_yticks(range(8))
221     ax.set_yticklabels(SHORT, color=TEXT, fontsize=9)
222
223     for ii in range(8):
224         for jj in range(8):
225             v = tau_mat[ii,jj]
226             bold = 'bold' if ii!=jj and abs(v)>0.10 else 'normal'
227             ax.text(jj, ii, f'{v:.2f}', ha='center', va='center',
228                     color='black', fontsize=9, fontweight=bold)
229
230     cbar = plt.colorbar(im, ax=ax, shrink=0.8)
231     cbar.ax.yaxis.set_tick_params(color=TEXT, labelcolor=TEXT)
232     ax.set_title('Matrice Kendall tau -- 8 garanties (28 paires)\n'

```

```

231         'Valeurs en gras = dependance significative ( $|\tau| >$ 
232           0.10)',
233         color=TEXT, fontsize=12, fontweight='bold', pad=12)
234
235 for sp in ax.spines.values(): sp.set_color(GRID)
236
237 path = os.path.join(Script_DIR, 'fig3_heatmap_kendall.png')
238 plt.tight_layout()
239 plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
240 plt.close()
241 print(f" [OK] fig3_heatmap_kendall.png")
242
243 # =====
244 # FIGURE 4 -- Scatter plots copule (uniformes empiriques)
245 #           3 paires les plus fortes
246 # =====
247 def fig4_scatter_copules():
248     top3 = sig_df.head(3)['Paire'].tolist()
249     fig, axes = plt.subplots(1, 3, figsize=(18, 6))
250     fig.patch.set_facecolor(DARK)
251     pair_colors = ['#e67e22', '#9b59b6', '#1abc9c']
252
253     for ax, plabel, color in zip(axes, top3, pair_colors):
254         ax.set_facecolor(PANEL)
255         idx_i = labels.index(plabel.split(' <-> ')[0])
256         idx_j = labels.index(plabel.split(' <-> ')[1])
257         tau_v = dep_df[dep_df['Paire']==plabel]['Kendall tau'].values[0]
258         cop_v = cop_df[cop_df['Paire']==plabel]['Copule'].values[0] \
259             if plabel in cop_df['Paire'].values else 'N/A'
260
261         ax.scatter(U[:,idx_i], U[:,idx_j], alpha=0.4, s=18, color=color)
262         ax.set_title(f'{plabel}\ntau = {tau_v:.3f} | Copule : {cop_v.
263             capitalize()}',
264             color=TEXT, fontsize=10, fontweight='bold')
265         ax.set_xlabel(f'U({SHORT[idx_i]})', color=TEXT, fontsize=9)
266         ax.set_ylabel(f'U({SHORT[idx_j]})', color=TEXT, fontsize=9)
267         ax.tick_params(colors=TEXT, labelsize=8)
268         ax.set_xlim(0,1); ax.set_ylim(0,1)
269         # Diagonal reference
270         ax.plot([0,1],[0,1], color='white', lw=0.8, alpha=0.3, linestyle
271             ='--')
272         for sp in ax.spines.values(): sp.set_color(GRID)
273
274     fig.suptitle('Espace des copules -- 3 paires avec la dependance la
275         plus forte',
276         color=TEXT, fontsize=13, fontweight='bold', y=1.02)
277     path = os.path.join(Script_DIR, 'fig4_scatter_copules.png')
278     plt.tight_layout()

```

```

274 plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
275 plt.close()
276 print(f" [OK] fig4_scatter_copules.png")
277
278 # =====
279 # FIGURE 5 -- Copule selectionnee par paire (barres horizontales)
280 # =====
281 def fig5_copules_bar():
282     fmap = {'gumbel': '#e74c3c', 'clayton': '#3498db', 'frank': '#2ecc71',
283            'gaussian': '#9b59b6', 'indep': '#95a5a6'}
284
285     fig, ax = plt.subplots(figsize=(12, 8))
286     fig.patch.set_facecolor(DARK); ax.set_facecolor(PANEL)
287
288     short_p = [p.replace('Incendie (total)', 'Incend.')]
289                .replace('Dommages (total)', 'Dommag.')]
290                .replace('Gros Incendies', 'GrosInc.')]
291                .replace('Gros Dommages', 'GrosDam.')]
292                .replace('RC (TPL)', 'RC') for p in cop_df['Paire']]
293     bc = [fmap.get(f.lower(), '#aaa') for f in cop_df['Copule']]
294     ypos = range(len(cop_df))
295     bars = ax.barh(list(ypos), cop_df['Log-Lik'], color=bc,
296                   edgecolor='none', height=0.65)
297
298     for bar, fname, ll in zip(bars, cop_df['Copule'], cop_df['Log-Lik']):
299         :
300         ax.text(bar.get_width()+0.1, bar.get_y()+bar.get_height()/2,
301               f'{fname.capitalize()} ({ll:.1f})',
302               va='center', color='white', fontsize=9)
303
304     ax.set_yticks(list(ypos))
305     ax.set_yticklabels(short_p, color=TEXT, fontsize=8)
306     ax.set_xlabel('Log-vraisemblance', color=TEXT, fontsize=10)
307     ax.set_title('Copule selectionnee par paire significative\n(critere
308                  AIC, methode CML)',
309                  color=TEXT, fontsize=12, fontweight='bold', pad=12)
310     ax.tick_params(colors=TEXT)
311     ax.grid(axis='x', color=GRID, alpha=0.4, lw=0.5)
312     for sp in ax.spines.values(): sp.set_color(GRID)
313
314     # Legende couleurs
315     from matplotlib.patches import Patch
316     legend_elements = [Patch(facecolor=v, label=k.capitalize())
317                        for k,v in fmap.items()]
318     ax.legend(handles=legend_elements, fontsize=9, facecolor=PANEL,
319              labelcolor=TEXT, loc='lower right')

```

```

319     path = os.path.join(SCRIPT_DIR, 'fig5_copules_bar.png')
320     plt.tight_layout()
321     plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
322     plt.close()
323     print(f"    [OK] fig5_copules_bar.png")
324
325     # =====
326     # FIGURE 6 -- Distribution perte agregée + seuils VaR
327     # =====
328     def fig6_distribution_agreee():
329         fig, ax = plt.subplots(figsize=(14, 6))
330         fig.patch.set_facecolor(DARK); ax.set_facecolor(PANEL)
331
332         pct = np.percentile(total, 99.5)
333         ax.hist(total[total<=pct]/1e6, bins=150, density=True,
334                color='#6c8ebf', alpha=0.75, edgecolor='none',
335                label='Scenarios simules (100 000)')
336
337         cmap_v = ['#f39c12', '#e67e22', '#e74c3c', '#c0392b', '#922b21']
338         for cv, res in zip(cmap_v, cap_results):
339             v = res['VaR']
340             if v/1e6 <= pct/1e6:
341                 ax.axvline(v/1e6, color=cv, lw=2, linestyle='--',
342                           label=f"VaR {res['Seuil']} = {v/1e6:.1f} MEUR")
343
344         # Zone de queue
345         x99 = cap_results[2]['VaR']/1e6
346         ax.axvspan(x99, pct/1e6, alpha=0.08, color='#e74c3c',
347                   label='Queue (>VaR 99%)')
348
349         ax.set_title('Distribution de la charge agregée mensuelle (8
350                      garanties)\n'
351                      'Simulation Monte Carlo -- Vine Copule',
352                      color=TEXT, fontsize=12, fontweight='bold', pad=12)
353         ax.set_xlabel('Charge totale mensuelle (MEUR)', color=TEXT, fontsize
354                      =11)
355         ax.set_ylabel('Densité', color=TEXT, fontsize=11)
356         ax.tick_params(colors=TEXT)
357         ax.legend(fontsize=9, facecolor=PANEL, labelcolor=TEXT,
358                  ncol=2, loc='upper right', framealpha=0.85)
359         ax.grid(axis='y', color=GRID, alpha=0.3, lw=0.5)
360         for sp in ax.spines.values(): sp.set_color(GRID)
361
362         path = os.path.join(SCRIPT_DIR, 'fig6_distribution_agreee.png')
363         plt.tight_layout()
364         plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
365         plt.close()

```

```

364     print(f"    [OK] fig6_distribution_agreee.png")
365
366     # =====
367     # FIGURE 7 -- VaR vs TVaR vs Independance (barres groupées)
368     # =====
369     def fig7_capital_var_tvar():
370         fig, ax = plt.subplots(figsize=(12, 6))
371         fig.patch.set_facecolor(DARK); ax.set_facecolor(PANEL)
372
373         xp = np.arange(len(levels)); w = 0.25
374         ax.bar(xp-w, [r['VaR']/1e6 for r in cap_results],
375              w, color='#3498db', label='VaR (copule)', alpha=0.9)
376         ax.bar(xp, [r['TVaR']/1e6 for r in cap_results],
377              w, color='#e74c3c', label='TVaR (copule)', alpha=0.9)
378         ax.bar(xp+w, [r['VaR_indep']/1e6 for r in cap_results],
379              w, color='#95a5a6', label='VaR (independance)', alpha=0.9)
380
381         # Annotations % gain
382         for i, res in enumerate(cap_results):
383             ax.text(i-w/2, res['VaR']/1e6 + 2,
384                  f"-{res['Div']:.0f}%", ha='center',
385                  color='#3498db', fontsize=8, fontweight='bold')
386
387         ax.set_xticks(xp)
388         ax.set_xticklabels([r['Seuil'] for r in cap_results],
389                          color=TEXT, fontsize=10)
390         ax.set_ylabel('MEUR / mois', color=TEXT, fontsize=11)
391         ax.set_title('Besoins en fonds propres -- VaR vs TVaR vs Hypothese d
392                    \'independance\n\'
393                    \'Les % indiquent le gain de diversification de la
394                    copule vs independance\',
395                    color=TEXT, fontsize=12, fontweight='bold', pad=12)
396         ax.tick_params(colors=TEXT)
397         ax.legend(fontsize=10, facecolor=PANEL, labelcolor=TEXT)
398         ax.grid(axis='y', color=GRID, alpha=0.3, lw=0.5)
399         for sp in ax.spines.values(): sp.set_color(GRID)
400
401         path = os.path.join(SCRIPDIR, 'fig7_capital_var_tvar.png')
402         plt.tight_layout()
403         plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
404         plt.close()
405         print(f"    [OK] fig7_capital_var_tvar.png")
406
407     # =====
408     # FIGURE 8 -- Tableau recapitulatif des resultats
409     # =====
410     def fig8_tableau_recap():

```

```

409 fig, axes = plt.subplots(1, 3, figsize=(20, 7))
410 fig.patch.set_facecolor(DARK)
411
412 def make_table(ax, data, col_labels, row_labels, title, col_colors):
413     ax.set_facecolor(DARK); ax.axis('off')
414     table = ax.table(
415         cellText=data,
416         colLabels=col_labels,
417         rowLabels=row_labels,
418         cellLoc='center',
419         loc='center'
420     )
421     table.auto_set_font_size(False)
422     table.set_fontsize(8)
423     table.scale(1, 1.6)
424     for (r, c), cell in table.get_celld().items():
425         cell.set_facecolor(PANEL if r > 0 else '#2a2d3a')
426         cell.set_text_props(color=TEXT)
427         cell.set_edgecolor(GRID)
428     ax.set_title(title, color=TEXT, fontsize=11,
429                 fontweight='bold', pad=15)
430
431 # Tableau 1 -- Lois marginales
432 data1 = [[best_fits[c]['dist'],
433           f"{stats.lognorm.fit(df[c].values, floc=0)[0]:.2f}" if
434           best_fits[c]['dist']=='Lognormale' else '--']
435         for c in cols_adj]
436 make_table(axes[0], data1,
437           ['Loi retenue', 'Param. sigma'],
438           [l[:15] for l in labels],
439           'Lois marginales', None)
440
441 # Tableau 2 -- Top dependances
442 top8 = sig_df.head(8)
443 data2 = [[f"{row['Kendall tau']:.3f}", f"{row['p-val']:.4f}",
444           f"{row['Spearman rho']:.3f}"]
445         for _, row in top8.iterrows()]
446 make_table(axes[1], data2,
447           ['Kendall tau', 'p-val', 'Spearman rho'],
448           [p[:22] for p in top8['Paire']],
449           'Top 8 dependances', None)
450
451 # Tableau 3 -- Capital
452 data3 = [[f"{r['VaR']/1e6:.1f}",
453           f"{r['TVaR']/1e6:.1f}",
454           f"{r['VaR_indep']/1e6:.1f}",
455           f"{r['Div']:.1f}%"]

```



```

455         for r in cap_results]
456     make_table(axes[2], data3,
457               ['VaR', 'TVaR', 'VaR indep.', 'Gain %'],
458               [r['Seuil'] for r in cap_results],
459               'Capital (MEUR/mois)', None)
460
461     fig.suptitle('Resume des resultats -- Methodologie Cadoux (2004)',
462                 color=TEXT, fontsize=14, fontweight='bold', y=1.02)
463
464     path = os.path.join(Script_DIR, 'fig8_tableau_recap.png')
465     plt.tight_layout()
466     plt.savefig(path, dpi=150, bbox_inches='tight', facecolor=DARK)
467     plt.close()
468     print(f"    [OK] fig8_tableau_recap.png")
469
470     # =====
471     # LANCEMENT DE TOUTES LES FIGURES
472     # =====
473     print("=" * 50)
474     print("Generation des figures individuelles")
475     print("=" * 50)
476
477     fig1_series_temporelles()
478     fig2_marginales()
479     fig3_heatmap_kendall()
480     fig4_scatter_copules()
481     fig5_copules_bar()
482     fig6_distribution_agreee()
483     fig7_capital_var_tvar()
484     fig8_tableau_recap()
485
486     print("\n" + "=" * 50)
487     print(f"8 figures sauvegardees dans :")
488     print(f"    {Script_DIR}")
489     print("=" * 50)

```